

---

# E-Portfolio

## Santander Customer Transaction Prediction

---

|                                |                                                                    |
|--------------------------------|--------------------------------------------------------------------|
| <b>Name</b>                    | Cyprian Sawarzynski                                                |
| <b>Modul</b>                   | Advanced Data Analytics / Scientific Programming and Data Analysis |
| <b>Semester</b>                | Sommersemester 2026                                                |
| <b>Gruppennummer</b>           | 138                                                                |
| <b>Gruppenmitglieder</b>       | Tim Hebestreit (Gruppenleiter), Angeline Usanayo, Trong Cao        |
| <b>Sprecher/Gruppenleitung</b> | Tim Hebestreit                                                     |
| <b>Abgabetermin</b>            | 01.09.2026                                                         |

# Inhaltsverzeichnis

|          |                                                     |          |
|----------|-----------------------------------------------------|----------|
| <b>1</b> | <b>Projektüberblick und Fragestellung</b>           | <b>2</b> |
| 1.1      | Datensatz und Aufgabenstellung . . . . .            | 2        |
| 1.2      | Eigene Forschungsfrage . . . . .                    | 2        |
| 1.3      | Projektziel . . . . .                               | 2        |
| <b>2</b> | <b>Individuelles Logbuch</b>                        | <b>2</b> |
| <b>3</b> | <b>Zusammenfassung des Logbuchs</b>                 | <b>3</b> |
| 3.1      | Fragestellung und Ziel . . . . .                    | 3        |
| 3.2      | Vorgehen und Methodeneinsatz . . . . .              | 3        |
| 3.3      | Iterationen und begründete Entscheidungen . . . . . | 3        |
| 3.4      | Ergebnisse . . . . .                                | 3        |
| 3.5      | Grenzen, Unsicherheiten und Ausblick . . . . .      | 4        |
| <b>4</b> | <b>Einschätzung der Gruppenmitglieder</b>           | <b>4</b> |
| <b>5</b> | <b>Ergebnisse der Gruppe</b>                        | <b>4</b> |
| <b>6</b> | <b>Protokoll der Gruppentreffen</b>                 | <b>4</b> |
| <b>7</b> | <b>Quellen und Hilfsmittel</b>                      | <b>4</b> |
| 7.1      | KI- und Tool-Transparenz . . . . .                  | 5        |
| <b>A</b> | <b>Abschluss-Checkliste</b>                         | <b>5</b> |

# 1 Projektüberblick und Fragestellung

## 1.1 Datensatz und Aufgabenstellung

Das Projekt behandelt den Datensatz *Santander Customer Transaction Prediction*. Die Daten stammen aus einer Kaggle Competition aus dem Jahr 2019. Auf Basis von Finanztransaktionsmerkmalen soll vorhergesagt werden, ob eine Person eine Transaktion durchführen wird.

- OpenML-Datensatz: ID 45566
- Kaggle: <https://www.kaggle.com/c/santander-customer-transaction-prediction>
- OpenML: <https://www.openml.org/search?type=data&status=active&id=45566>

## 1.2 Eigene Forschungsfrage

[PLACEHOLDER: präzise eigene Forschungsfrage ergänzen, z. B. welche Merkmale und Modelle die Transaktionsvorhersage besonders gut unterstützen.]

## 1.3 Projektziel

Ziel ist die Entwicklung, der Vergleich und die begründete Evaluation mehrerer Machine-Learning-Modelle für die binäre Klassifikationsaufgabe. Die Entscheidungen sollen durch die explorative Datenanalyse, geeignete Daten-Pipelines, passende Metriken und dokumentierte Modellvergleiche nachvollziehbar begründet werden.

# 2 Individuelles Logbuch

Das Logbuch wird chronologisch geführt. Jeder Eintrag dokumentiert Arbeitsschritte, Entscheidungen, verworfene Ansätze, Schwierigkeiten, Zeitaufwand und nächste Schritte.

## 06.08.2026 – Portfolio-Skelett und Projektauswahl

- Die Bewertungs- und Projektunterlagen wurden gelesen.
- Als Projektdatensatz wurde Santander Customer Transaction Prediction (OpenML ID 45566) festgehalten.
- Ein laufendes E-Portfolio wurde zunächst als Notebook angelegt und anschließend auf ein LaTeX-Dokument umgestellt.
- **Entscheidung:** Das Logbuch wird ab jetzt zeitnah nach jedem relevanten Arbeitsschritt ergänzt.
- **Zeitaufwand:** [PLACEHOLDER: Minuten/Stunden eintragen]
- **Gruppentreffen:** [PLACEHOLDER: kein Treffen / Treffen am ...]
- **Offene Fragen:** genaue Aufgabenverteilung, Forschungsfrage, Modellstrategie und verfügbarer Rechenrahmen.

[PLACEHOLDER: Datum] – [PLACEHOLDER: kurzer Titel]

- Arbeitsschritte: [PLACEHOLDER: ]
- Ergebnis/Erkenntnis: [PLACEHOLDER: ]
- Entscheidung und Begründung: [PLACEHOLDER: ]
- Verworfenе Ansätze oder Schwierigkeiten: [PLACEHOLDER: ]
- Nächster Schritt: [PLACEHOLDER: ]
- Zeitaufwand: [PLACEHOLDER: ]
- Bezug zum Gruppentreffen: [PLACEHOLDER: ]

### 3 Zusammenfassung des Logbuchs

*Dieser Abschnitt wird am Ende aus dem Logbuch entwickelt und auf maximal vier Seiten einschließlich Abbildungen und Tabellen verdichtet.*

#### 3.1 Fragestellung und Ziel

[PLACEHOLDER: Fragestellung, fachliche Motivation und Ziel der Analyse formulieren.]

#### 3.2 Vorgehen und Methodeneinsatz

[PLACEHOLDER: Datenzugang, Datentypen, EDA, Umgang mit fehlenden Werten, Train-Test-Aufteilung, Pipelines, Modelle, Learning Curves, Dimensionsreduktion und Hyperparameteroptimierung beschreiben.]

#### 3.3 Iterationen und begründete Entscheidungen

[PLACEHOLDER: Mehrere getestete Ansätze gegenüberstellen und anhand der Evaluationsergebnisse begründen.]

#### 3.4 Ergebnisse

[PLACEHOLDER: Zentrale Kennzahlen, Modellvergleich und wichtigste EDA-Befunde eintragen.]




Abbildung 1: [PLACEHOLDER: aussagekräftige Bildunterschrift]

### 3.5 Grenzen, Unsicherheiten und Ausblick

[PLACEHOLDER: Datenqualität, Rechenzeit, Generalisierbarkeit, mögliche Verzerrungen und konkrete nächste Schritte reflektieren.]

## 4 Einschätzung der Gruppenmitglieder

Dieser vertrauliche Abschnitt reflektiert die Zusammenarbeit. Für jede Person werden mindestens eine Stärke und ein Entwicklungsfeld mit kurzer Begründung ergänzt.

**Tim Hebestreit**

**Stärke:** [PLACEHOLDER: konkrete Stärke und Begründung]

**Entwicklungsfeld:** [PLACEHOLDER: konkretes Entwicklungsfeld und Begründung]

**Angeline Usanayo**

**Stärke:** [PLACEHOLDER: konkrete Stärke und Begründung]

**Entwicklungsfeld:** [PLACEHOLDER: konkretes Entwicklungsfeld und Begründung]

**Trong Cao**

**Stärke:** [PLACEHOLDER: konkrete Stärke und Begründung]

**Entwicklungsfeld:** [PLACEHOLDER: konkretes Entwicklungsfeld und Begründung]

## 5 Ergebnisse der Gruppe

**Hinweis:** Dieser Abschnitt ist laut Aufgabenstellung nur im Portfolio der Sprecherin enthalten. Tim Hebestreit führt als Gruppenleiter die gemeinsame Darstellung.

[PLACEHOLDER: Falls von Tim freigegeben, hier auf die finale Gruppenzusammenfassung und zentrale gemeinsame Ergebnisse verweisen.]

## 6 Protokoll der Gruppentreffen

**Hinweis:** Dieser Abschnitt ist laut Aufgabenstellung nur im Portfolio der Sprecherin enthalten. Eigene Bezüge zu Treffen werden zusätzlich im Logbuch dokumentiert.

[PLACEHOLDER: Verweis auf Tims Protokoll bzw. relevante Treffen ergänzen, sofern erforderlich.]

## 7 Quellen und Hilfsmittel

**Zitierstil:** [PLACEHOLDER: z. B. APA 7 oder Harvard verbindlich festlegen]

**Waack, J.-M. (2026).**

*Bewertungshinweise ADA*, SoSe 2026. Verwendung: Anforderungen und Bewertung des E-Portfolios. Zugriff: Projektunterlagen.

**OpenML, Datensatz ID 45566.**

*Santander Customer Transaction Prediction*. Verwendung: Datenquelle. Zugriff: [PLACEHOLDER: Zugriffsdatum ergänzen].

**Kaggle.**

*Santander Customer Transaction Prediction.* Verwendung: Wettbewerbskontext und Datensatzbeschreibung. Zugriff: [PLACEHOLDER: Zugriffsdatum ergänzen].

**Software.**

Python, Jupyter, pandas, NumPy, scikit-learn, matplotlib und seaborn. Verwendete Versionen: [PLACEHOLDER: Versionen eintragen].

**Generative KI.**

Tool, Zweck und relevante Prompts: [PLACEHOLDER: transparent dokumentieren]. Datum: [PLACEHOLDER: Datum].

## 7.1 KI- und Tool-Transparenz

Für jeden relevanten Einsatz werden Datum, Tool/Version, Zweck, Prompt bzw. Kurzbeschreibung, Ergebnis und die eigene Prüfung des Ergebnisses dokumentiert.

## A Abschluss-Checkliste

- Name, Gruppennummer, Thema und Gruppenmitglieder ergänzt
- Forschungsfrage und Ziel präzisiert
- Logbuch chronologisch und zeitnah geführt
- Entscheidungen, verworfene Ansätze, Schwierigkeiten und Iterationen dokumentiert
- EDA-Erkenntnisse mit Modellentscheidungen verknüpft
- Modelle, Metriken, Pipelines, Learning Curves und Hyperparameter beschrieben
- Abbildungen/Tabellen nummeriert, beschriftet und interpretiert
- Gruppenmitglieder fair und konkret eingeschätzt
- Quellen, Softwareversionen und KI-Nutzung vollständig dokumentiert
- PDF kompiliert und nach dem vorgegebenen Schema benannt