
E-Portfolio

Santander Customer Transaction Prediction

Name	Cyprian Sawarzynski
Modul	Advanced Data Analytics / Scientific Programming and Data Analysis
Semester	Sommersemester 2026
Gruppennummer	138
Thema	Santander Customer Transaction Prediction
Gruppenmitglieder	Tim Hebestreit, Angeline Usanayo, Trong Cao
Sprecher/Gruppenleitung	Tim Hebestreit
Abgabetermin	01.09.2026

Inhaltsverzeichnis

1	Zusammenfassung des Logbuchs	2
1.1	Fragestellung, Datenbasis und Ziel	2
1.2	EDA: belastbare Befunde statt visueller Ueberinterpretation	2
1.3	Transfer in die ML-Pipeline und zusaetzliche Kriterienpruefungen	3
1.4	Modellvergleich, Ergebnis und Interpretation	3
1.5	Korrekturen, Grenzen und konkreter Ausblick	4
2	Einschaetzung der Gruppenmitglieder	5
3	Quellen und Hilfsmittel	5
A	Individuelles Logbuch	6
A.1	Rahmen, Rekonstruktion und Workload	6
A.2	Woche 1: Explorative Datenanalyse (30.07.–06.08., 23,0 h)	6
A.3	Woche 2: Machine-Learning-Pipeline (06.08.–15.08., 28,0 h)	9
A.4	Woche 3: Vorbereitung des Portfolios (15.08.–29.08., 15,0 h)	12
A.5	Abschliessender Entscheidungsstand	15

1 Zusammenfassung des Logbuchs

1.1 Fragestellung, Datenbasis und Ziel

Mein Arbeitsanteil untersucht, **welche statistisch stabilen Unterschiede zwischen `target=False` und `target=True` in 200 anonymisierten numerischen Features erkennbar sind und welche daraus abgeleiteten Modellanpassungen unter starker Klassenimbalance tatsaechlich messbar helfen**. Ziel ist nicht nur ein hoher Score, sondern eine nachvollziehbare Kette von der EDA ueber train-only Preprocessing und Validation-Auswahl bis zur internen Testauswertung. Die 66 dokumentierten Stunden verteilen sich auf EDA (23 h), ML-Pipeline (28 h) und Portfolio/Qualitaetssicherung (15 h); Details stehen in Tabelle 2 des Anhangs.

Der OpenML-Datensatz 45566 [2] enthaelt 200.000 Beobachtungen, 200 kontinuierliche Features und das binaere Label. Es fehlen keine Werte, es existieren keine nicht-finiten Featurezellen und keine konstanten Features. Nur 20.098 Faelle (10,049 %) sind positiv. Eine reine Accuracy waere daher irrefuehrend; fuer Modellranking nutze ich primaer Average Precision (AP), ergaenzt um ROC-AUC, Kalibrierungs- und schwellenabhaengige Metriken.

1.2 EDA: belastbare Befunde statt visueller Ueberinterpretation

Fuer jedes Feature wurden deskriptive Kennzahlen, Ausreisserindikatoren, Klassenverteilungen, Welch-Tests, Benjamini-Hochberg-FDR, Cohen's d , Bootstrapintervalle und Mutual Information bestimmt. Der groesste absolute Effekt tritt bei `var_81` auf ($d = -0,2700$), der staerkste positive bei `var_6` ($d = 0,2224$). Nach FDR-Korrektur sind 181/200 Features signifikant. Das wird wegen der grossen Stichprobe nicht mit praktischer Relevanz gleichgesetzt: Die Effekte bleiben klein und werden ueber Stabilitaet und Visualisierung eingeordnet. Fuenf 1:1-Sensitivitaetsstichproben liefern fast identische d -Ranglisten (Spearman ca. 0,996; Logbuch 03.08.).




Abbildung 1: Top-20 standardisierte Klassenunterschiede. Take-away: Viele kleine, gerichtete Signale statt eines dominanten Features sprechen gegen aggressive Vorselektion.

Die Feature-Feature-Korrelationen sind schwach; kein Paar erreicht $|r| \geq 0,8$. Label-konditionierte Korrelationsaenderungen bleiben ebenfalls klein (Maximum ca. 0,0315). PCA, t-SNE, K-Means und DBSCAN zeigen in zwei Dimensionen keine klare Targettrennung. Die ersten zwei Min-Max-PCA-Komponenten erklaren jedoch nur 1,4363 %, die ersten 20 nur 12,9878 % der Varianz. Fehlende 2D-Trennung ist deshalb kein Beleg gegen Vorhersagbarkeit. Eine train-test-getrennte Logistic-Regression bestaetigt dies mit ROC-AUC 0,8599 und AP 0,5004 (Logbuch 06.08.).

Ergebnis: Die EDA stuetzt drei Leitplanken: alle 200 Features behalten, kein PCA-Bottleneck vorsehen und Modellwahl unter Imbalance an Validation-AP statt Accuracy ausrichten.

1.3 Transfer in die ML-Pipeline und zusaetzliche Kriterienpruefungen

Die Daten wurden stratifiziert in 128.000 Train-, 32.000 Validation- und 40.000 Hold-out-Faelle geteilt. Skalierer und Quantiltransformationen werden nur auf Train gefittet; Hyperparameter, Modellranking und F1-Schwellen stammen nur aus Validation. Getestet wurden GaussianNB und ANN jeweils als Standard- und EDA-adaptierte Variante. GaussianNB prueft, ob eine Quantilnormalisierung und abgestimmtes `var_smoothing` helfen. Beim ANN wird ein kleines MLP mit einem groesseren MLP mit Quantiltransformation, BatchNorm, Dropout, AdamW und train-basiertem `pos_weight=8,9518` verglichen.

Zwei nachtraegliche, ausschliesslich auf Train/Validation ausgefuehrte Diagnosen decken explizite Bewertungshinweise ab. Die Learning Curve in Abbildung 2 zeigt: Bereits 6.400 Trainingsfaelle ergeben AP 0,538; 32.000 ergeben 0,571 und alle 128.000 ergeben 0,581. Kleine Vorlaeufer sind sinnvoll, mehr Daten helfen weiter, der Zugewinn flacht aber ab. Die PCA-Pruefung in Abbildung 3 erreicht mit 10/25/50/100 Komponenten AP 0,440/0,446/0,456/0,478, klar unter 0,581 ohne PCA. Damit ist der Verzicht auf Kompression nicht nur ueber erklarte Varianz, sondern direkt ueber Validationleistung begruend.




Abbildung 2: Trainingsmengendiagnose auf Validation.




Abbildung 3: Train-only PCA-Vergleich auf Validation.

1.4 Modellvergleich, Ergebnis und Interpretation

Die vier Varianten wurden *vor ihrer Bewertung auf dem ML-Hold-out* nach Validation-AP gerankt (Abbildung 4). Standard-GaussianNB gewinnt knapp vor der quantiltransformierten Variante; die Anpassung verbessert also die primäre Metrik nicht. Das EDA-ANN gewinnt gegenüber dem Small ANN deutlich, bleibt aber hinter beiden NB-Modellen. Da im EDA-ANN mehrere Dinge gleichzeitig geändert werden, ist der Zugewinn als Effekt des Gesamtpakets und nicht einer einzelnen Komponente zu interpretieren.




Abbildung 4: Validation-Ranking vor der Bewertung der vier neuen Modelle auf dem Hold-out. Take-away: Standard-GaussianNB wird nach der vorab festgelegten AP ausgewählt.

Tabelle 1: Modellvergleich. AP/ROC-AUC sind schwellenunabhaengig; F1 und Brier stammen aus dem internen Hold-out, F1 bei der zuvor auf Validation bestimmten Schwelle.

Modell	Val. AP	Test AP	Test ROC	Test F1	Brier
NB Standard	0,5805	0,5755	0,8881	0,5450	0,0611
NB EDA-adaptiert	0,5797	0,5734	0,8879	0,5460	0,0612
ANN Small	0,4686	0,4666	0,8464	0,4662	0,0697
ANN EDA-adaptiert	0,5076	0,5030	0,8608	0,4865	0,1505

Beim ausgewaehlten Standard-NB senkt der Validation-F1-Threshold 0,2683 gegenueber 0,5 die Entscheidungsschwelle. Auf dem Hold-out steigt Recall von 0,3473 auf 0,5604, waehrend Precision von 0,7112 auf 0,5304 sinkt; F1 steigt von 0,4667 auf 0,5450. Das ist eine Betriebsentscheidung, keine Aenderung der Rankingqualitaet. Das gewichtete EDA-ANN erzielt zwar bessere AP als das Small ANN, ist mit Brier 0,1505 aber wesentlich schlechter kalibriert als NB (ca. 0,061). Ranking, Schwellenwahl und Kalibrierung muessen daher getrennt behandelt werden ([Confusion Matrices im Logbuch](#)).

Alle gespeicherten ML-Predictions wurden unabhaengig nachgerechnet: Die maximale absolute Abweichung zu `results.csv` betraegt $1,11 \cdot 10^{-16}$, alle vier Validation-F1-Schwellen stimmen exakt. Fuer Standard-NB ergibt der 200-fache Bootstrap AP [0,5615; 0,5906] und ROC-AUC [0,8838; 0,8933].

Ergebnis: Endstand meines Arbeitsanteils ist Standard-GaussianNB mit Validation-AP 0,5805 und interner Test-AP 0,5755. Mehr Modellkomplexitaet war kein Qualitaetskriterium; die einfachste Variante gewann nach der vorab festgelegten Metrik.

1.5 Korrekturen, Grenzen und konkreter Ausblick

Bei der Abschlusspruefung wurde ein echter EDA-Fehler gefunden: Welch-p-Werte waren positionsbasiert an eine nach $|d|$ sortierte Tabelle angehaengt. Dadurch waren einzelne Feature-p-Wert-Zuordnungen falsch, obwohl die Gesamtzahl 181 gleich blieb. Die Werte werden nun ueber Feature-Namen ausgerichtet und das Notebook wurde vollstaendig neu ausgefuehrt ([Pruefeintrag 29.08.](#)). Ausserdem wurde die Bezeichnung “unberuehrtes Testset” korrigiert: Die vier ML-Modelle werden zwar erst nach ihrer Validation-Auswahl auf dem Hold-out bewertet, derselbe Split war aber bereits fuer die EDA-Logistic-Referenz betrachtet worden. Die Testwerte sind reproduzierbare interne Schaetzungen, keine vollstaendig blinde externe Evaluation.

Weitere Grenzen sind die anonymisierten Features, ein einzelner stratifizierter Split, ein ANN-Initialisierungsseed und eine F1-Schwelle ohne reale Fehlerkosten. Der naechste Schritt ist daher eine verschachtelte bzw. wiederholte stratifizierte Validierung auf einem neu definierten Developmentbereich, mehrere ANN-Seeds und erst danach eine separat reservierte Schlussbewertung. Fuer einen Einsatz muesste die Schwelle an Kosten von False Positives und False Negatives gekoppelt und bei Bedarf eine Kalibrierung nur innerhalb der Trainings-/Validationdaten vorgenommen werden.

2 Einschätzung der Gruppenmitglieder

Dieser vertrauliche Abschnitt muss auf eigenen Beobachtungen zu Arbeitsweise, Kommunikation und Zusammenarbeit beruhen. Die Projektdateien liefern dafür keine verlässliche Grundlage; deshalb wurden keine Eigenschaften erfunden. Vor Abgabe sind je eine konkrete Stärke und Schwäche mit kurzer Situation/Begründung persönlich zu ergänzen.

Tim Hebestreit

Stärke: [PERSÖNLICH ERGÄNZEN: beobachtete Stärke und Beispiel]

Schwäche/Entwicklungsfeld: [PERSÖNLICH ERGÄNZEN: beobachtete Schwäche und Beispiel]

Angeline Usanayo

Stärke: [PERSÖNLICH ERGÄNZEN: beobachtete Stärke und Beispiel]

Schwäche/Entwicklungsfeld: [PERSÖNLICH ERGÄNZEN: beobachtete Schwäche und Beispiel]

Trong Cao

Stärke: [PERSÖNLICH ERGÄNZEN: beobachtete Stärke und Beispiel]

Schwäche/Entwicklungsfeld: [PERSÖNLICH ERGÄNZEN: beobachtete Schwäche und Beispiel]

3 Quellen und Hilfsmittel

[1] **Waack, J.-M. (2026).**

Bewertungshinweise ADA, SoSe 2026, lokale Projekt-PDF. Verwendung: Aufgaben-, Portfolio- und Bewertungskriterien.

[2] **OpenML (Datensatz 45566).**

Santander Customer Transaction Prediction. OpenML-Datensatzseite 45566 (Zugriff: 06.08.2026). Verwendung: reproduzierbare Datenquelle und Metadaten.

[3] **Kaggle (2019).**

Santander Customer Transaction Prediction. Kaggle-Wettbewerbsseite (Zugriff: 06.08.2026). Verwendung: Wettbewerbskontext und Zieldefinition.

[4] **Software und Bibliotheken.**

Python 3.12.3, NumPy 2.0.0, pandas 2.2.3, SciPy, scikit-learn 1.6.1, PyTorch 2.12.0+cpu, matplotlib, seaborn und Jupyter. Konkrete Versionen des ML-Laufs stehen zusätzlich in `config.json`. Verwendung: Analyse, Modellierung, Evaluation, Visualisierung und reproduzierbare Artefakte.

[5] **Generative KI: OpenAI Codex (29.08.2026).**

Verwendung: Ordner- und Kriterienaudit, unabhängige Rechenprüfung, Korrekturvorschläge, Learning-Curve-/PCA-Diagnostik sowie Strukturierung von Portfolio und Logbuch. Prompt des Nutzers (wortnah): “Gehe durch meinen Ordner Cyp, ordne das Portfolio nach Bewertungskriterien, verteile die Logs auf drei Wochen, ergänze EDA-/ML-Plots und prüfe EDA- und ML-Berechnungen.” Alle Kennzahlen wurden gegen Notebook-Ausgaben bzw. gespeicherte Predictions geprüft; die persönliche Gruppenbewertung wurde bewusst nicht generiert. Bereits vor diesem Auftrag im Repository vorhandene Agentenunterstützung ist in den früheren Arbeitsständen erkennbar; deren vollständige Prompt-Historie lag für diese Dokumentation nicht vor.

A Individuelles Logbuch

Das folgende Logbuch ist der geforderte, nicht zum empfohlenen Hauptumfang zählende Anhang. Es dokumentiert Zwischenschritte, Varianten, Korrekturen, verworfene Ansätze, Zeitaufwand und den jeweils gewonnenen Informationsstand.

A.1 Rahmen, Rekonstruktion und Workload

Das Logbuch dokumentiert meinen individuellen Arbeitsprozess. Die Datums- und Stundenzuordnung wurde am Ende anhand der Notebooks, Dateistaende und gespeicherten Run-Artefakte rekonstruiert; sie bildet Arbeitspakete und Aufwand plausibel ab, ist aber keine minutengenaue Zeiterfassung. Fuer die drei vorgegebenen Phasen sind insgesamt 66 Stunden dokumentiert. Zeiten wurden nicht auf den Richtwert von 100 Stunden hochgerechnet. Zu den einzelnen Schritten lagen keine belastbaren Protokolle konkreter Gruppentreffen vor; deshalb werden keine Treffen erfunden. Die Eintraege beziehen sich auf meinen individuellen Schwerpunkt EDA, Naive Bayes und ANN.

Tabelle 2: Verteilung der dokumentierten Arbeitszeit auf die drei Projektphasen.

Zeitraum	Schwerpunkt	Zeit
30.07.–06.08.2026	Explorative Datenanalyse	23,0 h
06.08.–15.08.2026	Machine-Learning-Pipeline	28,0 h
15.08.–29.08.2026	Vorbereitung des Portfolios	15,0 h
Gesamt		66,0 h

A.2 Woche 1: Explorative Datenanalyse (30.07.–06.08., 23,0 h)

30.07.2026

Projektauftrag, Bewertung und Forschungsfrage

Arbeitsschritte: Bewertungshinweise und Santander-Aufgabenblatt gelesen; OpenML-ID 45566 und Kaggle-Kontext dokumentiert; persoenliche Frage formuliert: Welche stabilen Klassenunterschiede sind erkennbar und welche EDA-Hypothesen verbessern spaeter Modelle?

Ergebnis/Erkenntnis: Binaere Klassifikation mit anonymisierten Merkmalen; EDA und ML muessen ueber begruendete Entscheidungen, nicht nur ueber Plot- oder Modellmengen verbunden werden.

Entscheidung/naechster Schritt: Technische Datenqualitaet vor inhaltlicher Analyse pruefen; Quellen reproduzierbar halten.

Zeitaufwand: 2,0 h

31.07.2026

Datenzugang und technische Qualitaetspruefung

Arbeitsschritte: Datensatz geladen und lokal als CSV gesichert; Form, Datentypen, Missing Values, nicht-finite Werte, Duplikate und konstante Features geprueft.

Ergebnis/Erkenntnis: 200.000 Beobachtungen, 200 numerische Features und `target`; 20.098 positive Faelle (10,049 %); keine fehlenden oder nicht-finiten Featurewerte und keine konstanten Features.

Entscheidung/naechster Schritt: Keine Imputation erforderlich; Rohdaten wegen ihrer Groesse nicht versionieren, sondern OpenML als reproduzierbare Quelle nennen.

Zeitaufwand: 3,5 h

01.08.2026

Deskriptive Statistik, Klassenimbalance und Ausreisser

Arbeitsschritte: Minimum, Maximum, Mittelwert, Median, Varianz, Schiefe, Kurtosis, Kardinalitaet, dominante Werte und IQR-Extremwertanteile berechnet; Klassenverteilung und Verteilungsdiagnostik visualisiert.

Ergebnis/Erkenntnis: Alle 200 Eingaben sind kontinuierlich numerisch; 131 Features enthalten negative Werte. Der Positivanteil von rund 10 % macht Accuracy als alleinige Metrik ungeeignet.

Entscheidung/naechster Schritt: Average Precision als zentrale spaetere Rankingmetrik vormerken; Effektgroessen und Klassenverteilungen untersuchen.

Zeitaufwand: 4,0 h




Abbildung 5: EDA-Fortschritt: Klassenverteilung. Informationsgewinn: Eine triviale Negativvorhersage waere bereits etwa 90 % korrekt; deshalb werden PR/AP, Balanced Accuracy und klassenbezogene Fehler benoetigt.

02.08.2026

Klassenunterschiede und interpretierbare Verteilungsplots

Arbeitsschritte: Klassenweise Mittelwerte, Mediane und Standardabweichungen verglichen; gepooltes Cohen's d berechnet; Box- und Violinplots fuer starke positive, starke negative und nahezu effektfreie Features erstellt.

Ergebnis/Erkenntnis: Der groesste absolute standardisierte Mittelwertunterschied liegt bei `var_81` ($d = -0,2700$). Staerkster positiver Effekt ist `var_6` ($d = 0,2224$). Die Effekte sind ueberwiegend klein, aber ueber viele Features verteilt.

Korrektur/Entscheidung: Nicht alle 200 Einzelplots in den Ergebnistext aufnehmen; repraesentative Plots zeigen und die vollstaendige Rangliste numerisch erhalten.

Zeitaufwand: 4,0 h

03.08.2026

Welch-Tests, FDR, Stabilitaet und Mutual Information

Arbeitsschritte: Welch-Tests fuer alle Features, Benjamini-Hochberg-FDR, fuenf 1:1-Sensitivitaetsstichproben (Seeds 42–46), Bootstrap-Intervalle fuer Top-Effekte und Mutual Information auf einer reproduzierbaren Teilstichprobe berechnet.

Ergebnis/Erkenntnis: 181/200 Features sind FDR-signifikant. Die Cohen- d -Ranglisten der fuenf 1:1-Stichproben korrelieren mit Spearman ungefaehr 0,996. Wegen der grossen Stichprobe bedeutet Signifikanz dennoch nicht automatisch praktische Relevanz.

Korrektur: Bei der Abschlusspruefung am 29.08. wurde entdeckt, dass die p-Werte im urspruenglichen Notebook positionsbasiert an eine nach $|d|$ sortierte Tabelle angehaengt waren. Die featurebezogene Zuordnung war dadurch falsch; die Gesamtzahl 181 blieb zufaellig unveraendert. Die Zuordnung wurde auf einen expliziten Feature-Index umgestellt und neu ausgefuehrt.

Zeitaufwand: 4,0 h




Abbildung 6: EDA-Fortschritt: Top-20 nach Cohen's d . Informationsgewinn: Die Richtung und standardisierte Groesse der Klassenunterschiede sind direkt vergleichbar; kein einzelnes Feature dominiert stark genug fuer eine aggressive Vorselektion.

04.08.2026

Korrelation, Redundanz und Sensitivitaetsanalyse

Arbeitsschritte: Feature-Feature- und Feature-Target-Korrelationen berechnet; Diagonalen in Heatmaps maskiert; label-konditionierte Korrelationen auf voller und balancierter 1:1-Stichprobe verglichen.

Ergebnis/Erkenntnis: Kein Featurepaar erreicht $|r| \geq 0,8$. Die groesste label-konditionierte Korrelationsaenderung betraegt nur rund 0,0315. Empirisch enge Farbskalen koennen solche kleinen Differenzen optisch ueberzeichnen.

Verworfenen Ansatz/Entscheidung: Eine Korrelations-Zeilensumme erzeugte einen 14-Feature-Stress-Test, aber keine belastbare Targettrennung; sie wird nicht als finale Featureselektion verwendet.

Zeitaufwand: 3,0 h

06.08.2026

Skalierung, PCA/t-SNE, Clustering und ueberwachte Referenz

Arbeitsschritte: Roh-, Standard-, Min-Max- und robuste Skalierung fuer PCA verglichen; Scree-Plot, PCA/t-SNE auf allen Features sowie K-Means/DBSCAN erstellt; train-test-getrennte Logistic-Regression-Pipeline als ueberwachte Referenz gerechnet.

Ergebnis/Erkenntnis: Die ersten zwei Min-Max-PCA-Komponenten erklaren 1,4363 %, die ersten 20 nur 12,9878 %. Clusterlabels stimmen praktisch nicht mit dem Target ueberein. Logistic Regression erreicht ROC-AUC 0,8599 und AP 0,5004; Vorhersageinformation existiert also trotz fehlender 2D-Trennung.

Grenze/Entscheidung: t-SNE nutzt 20.000 reproduzierbar gezogene Zeilen; Achsen und globale Abstaende werden nicht inhaltlich interpretiert. Alle 200 Features bleiben fuer die erste ML-Runde erhalten.

Zeitaufwand: 2,5 h




Abbildung 7: EDA-Fortschritt: Scree-Plot. Informationsgewinn: Die Varianz ist breit ueber viele Dimensionen verteilt; eine zweidimensionale Projektion verwirft den groessten Teil der Information und darf nicht als Beleg gegen Klassifizierbarkeit dienen.

A.3 Woche 2: Machine-Learning-Pipeline (06.08.–15.08., 28,0 h)

06.08.2026

Modellhypothesen und reproduzierbare Run-Struktur

Arbeitsschritte: GaussianNB und ANN jeweils als Standard- und EDA-adaptierte Variante geplant; Konfiguration, Seeds, Logging, Run-Verzeichnis, Modelle, Predictions, Checkpoints, Historien und Plots als Artefakte vorgesehen.

Entscheidung: Alle Varianten verwenden dieselben 200 Features. Quantiltransformation, Klassengewichtung und Regularisierung sind pruefbare Hypothesen, keine vorausgesetzten Verbesserungen.

Zeitaufwand: 3,0 h

07.08.2026

Train-/Validation-/Hold-out-Aufteilung und Metriken

Arbeitsschritte: Stratifizierte Aufteilung in 128.000 Train- (64 %), 32.000 Validation- (16 %) und 40.000 Hold-out-Faelle (20 %); einheitliche Berechnung von ROC-AUC, AP, Brier, Log-Loss, Balanced Accuracy, Precision, Recall, F1, MCC und Spezifitaet implementiert.

Entscheidung: Preprocessing nur auf Train fitten; Hyperparameter, Modellranking und F1-Schwellen nur mit Validation bestimmen.

Grenze: Der Hold-out ist identisch mit dem bereits fuer die EDA-Logistic-Referenz betrachteten Split. Er ist innerhalb dieses ML-Laufs nicht fuer die Auswahl benutzt, aber projektweit nicht vollstaendig blind; Ergebnisse werden deshalb als interne Testwerte eingeordnet.

Zeitaufwand: 3,0 h

08.08.2026

GaussianNB-Standardbaseline

Arbeitsschritte: GaussianNB mit allen Rohfeatures und empirischen Klassenpriors trainiert; F1-optimale Schwelle auf Validation bestimmt.

Ergebnis/Erkenntnis: Validation: ROC-AUC 0,8876, AP 0,5805, F1 0,5505, Balanced Accuracy 0,7601; Validation-Schwelle 0,2683.

Entscheidung: Einfache probabilistische Baseline als Referenz fuer jede zusaetzliche Transformation und Modellkomplexitaet beibehalten.

Zeitaufwand: 3,5 h

09.08.2026

Quantil-adaptiertes GaussianNB und Hyperparametervergleich

Arbeitsschritte: QuantileTransformer nur auf Train gefittet; sieben `var_smoothing`-Werte von 10^{-12} bis 10^{-6} auf Validation verglichen.

Ergebnis/Erkenntnis: Bestes `var_smoothing` 10^{-12} ; Validation ROC-AUC 0,8891 und AP 0,5797. Die AP liegt trotz leicht hoeherer ROC-AUC unter der Standardvariante.

Entscheidung: Transformation nicht als Fortschritt werten, weil die primaere Validation-AP nicht steigt.

Zeitaufwand: 3,5 h

10.08.2026

ANN-Preprocessing und Architekturen

Arbeitsschritte: Train-only StandardScaler fuer Small ANN und train-only Quantiltransformation fuer EDA-ANN vorbereitet; Architekturen und Parameterzahlen geprueft.

Ergebnis/Erkenntnis: Small ANN: $200 \rightarrow 64 \rightarrow 32 \rightarrow 1$, 14.977 Parameter. EDA-ANN: $200 \rightarrow 128 \rightarrow 64 \rightarrow 32 \rightarrow 1$ mit BatchNorm/Dropout, 36.481 Parameter.

Zeitaufwand: 3,0 h

11.08.2026

Small ANN: Training und Early Stopping

Arbeitsschritte: Adam, ungewichtete BCEWithLogitsLoss, Checkpoints und getrennte Epochenmetriken implementiert; Validation Loss fuer Early Stopping genutzt.

Ergebnis/Erkenntnis: Validation-AP 0,4686. Die Trainingsleistung steigt weiter, waehrend die Validationsleistung frueh abflacht; ein groesserer Epochenumfang allein loest das Problem nicht.

Zeitaufwand: 3,0 h

12.08.2026

EDA-adaptiertes ANN und Imbalance-Behandlung

Arbeitsschritte: Quantilnormalisierung, BatchNorm, Dropout, AdamW und BCEWithLogitsLoss mit aus Train berechnetem `pos_weight=8,9518` kombiniert; Validation-AP fuer Early Stopping und LR-Scheduling genutzt.

Ergebnis/Erkenntnis: Validation-AP steigt gegenueber dem Small ANN von 0,4686 auf 0,5076. Die kombinierte Anpassung hilft dem ANN, bleibt aber unter beiden NB-Varianten.

Grenze: Da mehrere Komponenten gleichzeitig geaendert wurden, kann der Zugewinn nicht kausal einer einzelnen Anpassung zugeschrieben werden.

Zeitaufwand: 3,5 h

13.08.2026

Validation-Ranking und Modellentscheidung

Arbeitsschritte: Vier Varianten vor ihrer ML-Hold-out-Bewertung nach Validation-AP gerankt; F1-Schwellen aus Validation gespeichert.

Ergebnis/Erkenntnis: NB Standard 0,5805; NB EDA 0,5797; ANN EDA 0,5076; ANN Small 0,4686. NB Standard wird vor den neuen Testwerten ausgewählt.

Zeitaufwand: 2,5 h




Abbildung 8: ML-Fortschritt: Validation-Ranking. Informationsgewinn: Das einfache Standard-GaussianNB gewinnt nach der vorab festgelegten AP; weder Quantiltransformation noch höhere ANN-Komplexität rechtfertigen einen Wechsel.

Arbeitsschritte: ROC-/PR-Kurven, Confusion Matrices, Threshold-Diagnostik, Kalibrierung, Wahrscheinlichkeitsverteilungen und 200 Bootstrap-Wiederholungen erstellt; gespeicherte Vorhersagen und Tabellen exportiert.

Ergebnis/Erkenntnis: NB Standard erreicht AP 0,5755, ROC-AUC 0,8881 und F1 0,5450 bei Schwelle 0,2683. NB EDA: AP 0,5734/F1 0,5460; ANN Small: 0,4666/0,4662; ANN EDA: 0,5030/0,4865. Fuer NB Standard liegt das 95 %-Bootstrapintervall bei AP [0,5615; 0,5906] und ROC-AUC [0,8838; 0,8933].

Kalibrierung: Das EDA-ANN verbessert sein Ranking, besitzt aber Brier 0,1505 statt rund 0,061 bei NB; Ranking und Wahrscheinlichkeitskalibrierung sind getrennte Ziele.

Zeitaufwand: 3,0 h




Abbildung 9: ML-Ergebnis: Confusion Matrices bei Validation-Schwellen. Informationsgewinn: Die Matrizen zeigen konkrete False-Positive-/False-Negative-Kosten und machen sichtbar, dass ein besseres Ranking nicht automatisch denselben Betriebspunkt bedeutet.

A.4 Woche 3: Vorbereitung des Portfolios (15.08.–29.08., 15,0 h)

15.08.2026

Run-Artefakte verifiziert und Abbildungen ausgewählt

Arbeitsschritte: config.json, Split-Indizes, Validation-/Testergebnisse, Predictions, Historien, Checkpoints und Bootstrap-Tabelle des Runs 20260815_030409_NB_ANN gegeneinander geprüft; geeignete EDA-/ML-Plots für das Portfolio gesammelt.

Ergebnis/Erkenntnis: Modellentscheidung und berichtete Zahlen sind durch Run-Artefakte nachvollziehbar.

Zeitaufwand: 2,0 h

18.08.2026

EDA-Notebook konsolidiert und Interpretationen geschaerft

Arbeitsschritte: Doppelte bzw. zu breite Darstellungen reduziert; Achsen und Farbskalen vereinheitlicht; PCA/t-SNE- und Clusteringaussagen auf ihre tatsächliche Reichweite begrenzt.

Ergebnis/Erkenntnis: 2D-Überlappung ist kein Beleg gegen Vorhersagbarkeit; die Logistic-Referenz zeigt gerade den Unterschied zwischen Visualisierung und überwachtem Ranking.

Zeitaufwand: 2,5 h

20.08.2026

Bewertungsmatrix auf Portfolio-Inhalte abgebildet

Arbeitsschritte: Titelangaben, Logbuchanforderungen, Vier-Seiten-Grenze der Zusammenfassung, Gruppenreflexion, Quellen/KI-Transparenz und Abbildungsqualität gegen die offiziellen Kriterien geprüft.

Ergebnis/Erkenntnis: Das alte Dokument war 22 Seiten lang; die Zusammenfassung allein umfasste etwa sechs Seiten und das Logbuch stand vor der Zusammenfassung. Für die Abgabe wird der Hauptteil verdichtet und das Logbuch als nicht mitgezählter Anhang gesetzt.

Zeitaufwand: 2,0 h

22.08.2026

Zusammenfassung auf Entscheidungslogik verdichtet

Arbeitsschritte: Fragestellung, EDA-Befunde, EDA-zu-ML-Transfer, Modellvergleich, Schwellenwahl, Grenzen und Ausblick in eine kompakte Argumentation gebracht; Tabellen und Plots auf ihren Take-away reduziert.

Entscheidung: Nur Visualisierungen aufnehmen, die eine Entscheidung stützen; Detailplots bleiben im Logbuch bzw. in den Notebooks.

Zeitaufwand: 3,0 h

25.08.2026

Logbuch chronologisch und visuell überarbeitet

Arbeitsschritte: Vorhandene Einträge auf die drei vorgegebenen Phasen verteilt; Stunden so zugeordnet, dass die Wochensummen 23/28/15 h ergeben; EDA- und ML-Plots jeweils mit explizitem Informationsgewinn eingebettet.

Ergebnis/Erkenntnis: Varianten, verworfene Ansätze, Korrekturen und offene Grenzen sind nun im zeitlichen Aufbau sichtbar.

Zeitaufwand: 2,5 h

27.08.2026

Quellen, KI-Transparenz und Abgabeform geprüft

Arbeitsschritte: OpenML, Kaggle, Projektunterlagen, Softwareversionen und Einsatz generativer KI mit Zweck/Prompt dokumentiert; Dateiname und PDF-Struktur gegen die Abgabehinweise geprüft.

Offener Punkt: Die vertrauliche Einschätzung der drei Gruppenmitglieder kann nur von mir auf Basis realer Zusammenarbeit vervollständigt werden; sie wird nicht aus Dateien oder Namen erfunden.

Zeitaufwand: 1,5 h

Arbeitsschritte: EDA-Welch/FDR-Zuordnung korrigiert und Notebook vollstaendig neu ausgefuehrt; gespeicherte ML-Vorhersagen unabhaengig nachgerechnet; F1-Schwellen exakt reproduziert; Learning Curve und train-only PCA-Validierung ergaenzt; Portfolio kompiliert und Seiten/Verweise/Abbildungen geprueft.

Ergebnis/Erkenntnis: Alle gespeicherten ML-Metriken stimmen bis auf numerisches Rundungsrauschen (maximale Abweichung $1,11 \cdot 10^{-16}$); alle vier Validation- F1-Schwellen stimmen exakt. GaussianNB erreicht mit 1.280/6.400/32.000/128.000 Trainingsfaellen AP 0,419/0,538/0,571/0,581. PCA mit 10/25/50/100 Komponenten erreicht nur AP 0,440/0,446/0,456/0,478 gegenueber 0,581 ohne PCA.

Schlussfolgerung: Die Rechenwerte sind reproduzierbar; der Verzicht auf PCA ist nun auch metrisch begruendet. Wesentliche verbleibende Grenze ist die projektweite Vorbenutzung des Hold-outs sowie fehlende Split-/ANN-Seed-Stabilitaet.

Zeitaufwand: 1,5 h




Abbildung 10: Qualitaetssicherung: Learning Curve des Standard-GaussianNB. Informationsgewinn: Kleine Vorlaeufer liefern bereits ein sinnvolles Signal; mehr Trainingsdaten verbessern AP weiter, der Zugewinn flacht jedoch sichtbar ab.




Abbildung 11: Qualitaetssicherung: train-only PCA-Vergleich. Informationsgewinn: Keine der geprueften Kompressionen erreicht die Validation-AP des Modells ohne PCA; der Informationsverlust ueberwiegt den moeglichen Regularisierungsvorteil.

A.5 Abschliessender Entscheidungsstand

Bereich	Stand	Begrueundung/Beleg
Datenqualitaet	Keine Imputation	Keine fehlenden oder nicht-finiten Featurewerte.
Featurebasis	Alle 200 Features	Viele kleine stabile Effekte; keine starke lineare Redundanz.
Primaere Metrik	Validation AP	Aussagekraeftig bei rund 10 % positiven Faellen.
Dimensionsreduktion	Nicht verwendet	PCA 10–100: AP 0,440–0,478; ohne PCA 0,581.
Ausgewaehltes Modell	NB Standard	Hoechste Validation-AP 0,5805.
Interner Testwert	AP 0,5755; ROC 0,8881	Metriken aus Predictions exakt reproduziert.
Threshold	0,2683	F1-optimal ausschliesslich auf Validation.
Unsicherheit	Bootstrap + Grenzen	AP-CI [0,5615; 0,5906]; Split nicht projektweit blind.
Offene Robustheit	Weitere Splits/Seeds	Ein Hold-out und ein ANN-Seed reichen nicht fuer externe Generalisierbarkeit.