
E-Portfolio

Santander Customer Transaction Prediction

Name	Cyprian Sawarzynski
Modul	Advanced Data Analytics / Scientific Programming and Data Analysis
Semester	Sommersemester 2026
Gruppennummer	138
Gruppenmitglieder	Tim Hebestreit (Gruppenleiter), Angeline Usanayo, Trong Cao
Sprecher/Gruppenleitung	Tim Hebestreit
Abgabetermin	01.09.2026

Inhaltsverzeichnis

1	Projektüberblick und Fragestellung	2
1.1	Datensatz und Aufgabenstellung	2
1.2	Eigene Forschungsfrage	2
1.3	Projektziel	2
2	Individuelles Logbuch	2
3	Zusammenfassung des Logbuchs	2
3.1	Fragestellung und Ziel	2
3.2	Vorgehen und Methodeneinsatz	2
3.3	Iterationen und begründete Entscheidungen	2
3.4	Ergebnisse	3
3.5	Grenzen, Unsicherheiten und Ausblick	3
4	Einschätzung der Gruppenmitglieder	3
5	Ergebnisse der Gruppe	3
6	Protokoll der Gruppentreffen	4
7	Quellen und Hilfsmittel	4
7.1	KI- und Tool-Transparenz	4
A	Individuelles Logbuch	4
B	Zweck und Führungsregeln	4
C	Projekt- und Gruppenrahmen	5
D	Chronologische Einträge	5
E	Laufende Methodik- und Entscheidungsübersicht	17
F	Offene Fragen und Risiken	18
G	Hinweise für die spätere Zusammenfassung	18
H	Abschluss-Checkliste	19

1 Projektüberblick und Fragestellung

1.1 Datensatz und Aufgabenstellung

Das Projekt behandelt den Datensatz *Santander Customer Transaction Prediction*. Die Daten stammen aus einer Kaggle Competition aus dem Jahr 2019. Auf Basis von Finanztransaktionsmerkmalen soll vorhergesagt werden, ob eine Person eine Transaktion durchführen wird.

- OpenML-Datensatz: ID 45566
- Kaggle: <https://www.kaggle.com/c/santander-customer-transaction-prediction>
- OpenML: <https://www.openml.org/search?type=data&status=active&id=45566>

1.2 Eigene Forschungsfrage

[PLACEHOLDER: präzise eigene Forschungsfrage ergänzen, z. B. welche Merkmale und Modelle die Transaktionsvorhersage besonders gut unterstützen.]

1.3 Projektziel

Ziel ist die Entwicklung, der Vergleich und die begründete Evaluation mehrerer Machine-Learning-Modelle für die binäre Klassifikationsaufgabe. Die Entscheidungen sollen durch die explorative Datenanalyse, geeignete Daten-Pipelines, passende Metriken und dokumentierte Modellvergleiche nachvollziehbar begründet werden.

2 Individuelles Logbuch

Das vollständige, fortlaufend gepflegte Logbuch ist im Anhang eingebunden. Die separate Quelldatei bleibt dabei die einzige Stelle, an der die Einträge gepflegt werden.

3 Zusammenfassung des Logbuchs

Dieser Abschnitt wird am Ende aus dem Logbuch entwickelt und auf maximal vier Seiten einschließlich Abbildungen und Tabellen verdichtet.

3.1 Fragestellung und Ziel

[PLACEHOLDER: Fragestellung, fachliche Motivation und Ziel der Analyse ausformulieren.]

3.2 Vorgehen und Methodeneinsatz

[PLACEHOLDER: Datenzugang, Datentypen, EDA, Umgang mit fehlenden Werten, Train-Test-Aufteilung, Pipelines, Modelle, Learning Curves, Dimensionsreduktion und Hyperparameteroptimierung beschreiben.]

3.3 Iterationen und begründete Entscheidungen

[PLACEHOLDER: Mehrere getestete Ansätze gegenüberstellen und anhand der Evaluationsergebnisse begründen.]

3.4 Ergebnisse

[PLACEHOLDER: Zentrale Kennzahlen, Modellvergleich und wichtigste EDA-Befunde eintragen.]




Abbildung 1: [PLACEHOLDER: aussagekräftige Bildunterschrift]

3.5 Grenzen, Unsicherheiten und Ausblick

[PLACEHOLDER: Datenqualität, Rechenzeit, Generalisierbarkeit, mögliche Verzerrungen und konkrete nächste Schritte reflektieren.]

4 Einschätzung der Gruppenmitglieder

Dieser vertrauliche Abschnitt reflektiert die Zusammenarbeit. Für jede Person werden mindestens eine Stärke und ein Entwicklungsfeld mit kurzer Begründung ergänzt.

Tim Hebestreit

Stärke: [PLACEHOLDER: konkrete Stärke und Begründung]

Entwicklungsfeld: [PLACEHOLDER: konkretes Entwicklungsfeld und Begründung]

Angeline Usanayo

Stärke: [PLACEHOLDER: konkrete Stärke und Begründung]

Entwicklungsfeld: [PLACEHOLDER: konkretes Entwicklungsfeld und Begründung]

Trong Cao

Stärke: [PLACEHOLDER: konkrete Stärke und Begründung]

Entwicklungsfeld: [PLACEHOLDER: konkretes Entwicklungsfeld und Begründung]

5 Ergebnisse der Gruppe

Hinweis: Dieser Abschnitt ist laut Aufgabenstellung nur im Portfolio der Sprecherin enthalten. Tim Hebestreit führt als Gruppenleiter die gemeinsame Darstellung.

[PLACEHOLDER: Falls von Tim freigegeben, hier auf die finale Gruppenzusammenfassung und zentrale gemeinsame Ergebnisse verweisen.]

6 Protokoll der Gruppentreffen

Hinweis: Dieser Abschnitt ist laut Aufgabenstellung nur im Portfolio der Sprecherin enthalten. Eigene Bezüge zu Treffen werden zusätzlich im Logbuch dokumentiert.

[**PLACEHOLDER: Verweis auf Tims Protokoll bzw. relevante Treffen ergänzen, sofern erforderlich.**]

7 Quellen und Hilfsmittel

Zitierstil: [**PLACEHOLDER: z. B. APA 7 oder Harvard verbindlich festlegen**]
Waack, J.-M. (2026).

Bewertungshinweise ADA, SoSe 2026. Verwendung: Anforderungen und Bewertung des E-Portfolios. Zugriff: Projektunterlagen.

OpenML, Datensatz ID 45566.

Santander Customer Transaction Prediction. Verwendung: Datenquelle. Zugriff: [**PLACEHOLDER: Zugriffsdatum ergänzen**].

Kaggle.

Santander Customer Transaction Prediction. Verwendung: Wettbewerbskontext und Datensatzbeschreibung. Zugriff: [**PLACEHOLDER: Zugriffsdatum ergänzen**].

Software.

Python, Jupyter, pandas, NumPy, scikit-learn, matplotlib und seaborn. Verwendete Versionen: [**PLACEHOLDER: Versionen eintragen**].

Generative KI.

Tool, Zweck und relevante Prompts: [**PLACEHOLDER: transparent dokumentieren**].
Datum: [**PLACEHOLDER: Datum**].

7.1 KI- und Tool-Transparenz

Für jeden relevanten Einsatz werden Datum, Tool/Version, Zweck, Prompt bzw. Kurzbeschreibung, Ergebnis und die eigene Prüfung des Ergebnisses dokumentiert.

A Individuelles Logbuch

B Zweck und Führungsregeln

Dieses Logbuch dokumentiert meinen individuellen Arbeitsprozess während des gesamten Bearbeitungszeitraums. Es ist kein nachträglich geglätteter Ergebnisbericht, sondern hält den tatsächlichen Weg zur Analyse fest. Dadurch sollen Arbeitsaufwand, eigene Entscheidungen, Anpassungen, Schwierigkeiten und verworfene Ansätze nachvollziehbar bleiben.

Die Einträge werden chronologisch und möglichst unmittelbar nach dem jeweiligen Arbeitsschritt ergänzt. Jeder Eintrag enthält mindestens:

- Datum des Eintrags,
- einen kurzen und prägnanten Titel,
- eine verständliche Zusammenfassung des Arbeitsschritts.

Zusätzlich dokumentiere ich systematisch:

- konkrete Arbeitsschritte und Ergebnisse,

- methodische Entscheidungen und deren Begründung,
- verworfene Ansätze und Iterationen,
- Schwierigkeiten, Unsicherheiten und offene Fragen,
- Zeitaufwand und gegebenenfalls Bezug zu Gruppentreffen,
- nächste Schritte und Abweichungen vom vereinbarten Vorgehen.

Das Logbuch bildet die Grundlage für die spätere Zusammenfassung im E-Portfolio. Abbildungen oder Tabellen dürfen hier auch vorläufig bzw. als Arbeitsdokumentation eingefügt werden; für die finale Zusammenfassung werden die relevanten Darstellungen später formal ausgearbeitet.

C Projekt- und Gruppenrahmen

Thema	Santander Customer Transaction Prediction
Datensatz	OpenML ID 45566
Name	Cyprian Sawarzynski
Gruppennummer	138
Gruppenmitglieder	Tim Hebestreit (Gruppenleiter), Angeline Usanayo, Trong Cao
Sprecher/Gruppenleitung	Tim Hebestreit
Projektdeadline	01.09.2026
Individueller Workload-Richtwert	ca. 100 Stunden

D Chronologische Einträge

06.08.2026 – Projektunterlagen und Projektauswahl

Zusammenfassung

Die Bewertungs- und Projektunterlagen wurden gelesen. Als Projekt aus den vorhandenen Aufgaben wurde Santander Customer Transaction Prediction ausgewählt.

Arbeitsschritte

- Bewertungshinweise für das E-Portfolio gelesen.
- Anforderungen an EDA und Machine Learning herausgearbeitet.
- Santander-Aufgabenblatt gelesen und OpenML-Datensatz ID 45566 notiert.
- Kaggle- und OpenML-Links als spätere Quellen vorgemerkt.

Entscheidungen und Begründung

Die Analyse wird auf Santander fokussiert, weil die Aufgabe eine binäre Transaktionsvorhersage mit klarer OpenML-Referenz vorgibt. Die weitere Bearbeitung soll EDA-Erkenntnisse ausdrücklich mit den späteren Modellentscheidungen verbinden.

Schwierigkeiten und offene Fragen

Die genaue Aufgabenverteilung innerhalb der Gruppe, die persönliche Forschungsfrage, die Modellstrategie und der verfügbare Rechenrahmen sind noch zu klären.

Abweichung vom Vorgehen

Noch keine Abweichung vom Gruppenplan dokumentiert.

Gruppentreffen

[PLACEHOLDER: kein Treffen / Datum und Kurzverweis ergänzen]

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Logbuch und E-Portfolio als belastbare Arbeitsgrundlage anlegen und anschließend den Datensatz laden sowie technisch prüfen.

06.08.2026 – E-Portfolio auf LaTeX umgestellt

Zusammenfassung

Das zunächst als Notebook angelegte E-Portfolio wurde auf ein eigenständiges LaTeX-Dokument umgestellt. Ziel war ein besser kontrollierbares Layout für die spätere PDF-Abgabe.

Arbeitsschritte

- Ordner `E_Portfolio` im eigenen Projektordner angelegt.
- Hauptdatei `ADA_138_Sawarzynski_Portfolio.tex` erstellt.
- Titel, Projektüberblick, Logbuch-Platzhalter, Zusammenfassung, Gruppenreflexion, Quellen und Abschluss-Checkliste strukturiert.
- Ordner `assets` für spätere Abbildungen vorbereitet.
- LaTeX-Datei mit XeLaTeX kompiliert und PDF-Ausgabe geprüft.

Entscheidungen und Begründung

Das Logbuch wird als separate Datei geführt, damit der Arbeitsprozess unabhängig vom später verdichteten Portfolio fortlaufend ergänzt werden kann.

Schwierigkeiten und Lösungen

Die lokale TinyTeX-Installation enthielt mehrere optionale Pakete nicht. Die Präambel wurde deshalb auf vorhandene Standardpakete reduziert; die Ausgabe kompiliert nun erfolgreich.

Abweichung vom Vorgehen

Das ursprünglich geplante Notebook-Format wurde zugunsten von LaTeX verworfen, nachdem die PDF-Gestaltung von nbconvert nicht zufriedenstellend war.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Die EDA des Santander-Datensatzes beginnen und dabei Datenform, Datentypen, Zielvariable, fehlende Werte, Klassenverteilung und erste Verteilungen systematisch untersuchen.

[PLACEHOLDER: Datum] – [PLACEHOLDER: prägnanter Arbeitstitel]

Zusammenfassung

[PLACEHOLDER: Kurze Zusammenfassung des konkreten Arbeitsschritts.]

Arbeitsschritte

[PLACEHOLDER: Welche Schritte wurden tatsächlich durchgeführt?]

Ergebnis/Erkenntnis

[PLACEHOLDER: Was kam dabei heraus? Zahlen, Tabellen oder Abbildungen verlinken.]

Entscheidung und Begründung

[PLACEHOLDER: Welche Entscheidung wurde getroffen und warum?]

Verworfenne Ansätze/Schwierigkeiten

[PLACEHOLDER: Was hat nicht funktioniert oder wurde verworfen?]

Abweichung vom vereinbarten Vorgehen

[PLACEHOLDER: Keine / konkrete Abweichung mit Begründung.]

Gruppentreffen

[PLACEHOLDER: Datum, Teilnehmende und Bezug zum Treffen.]

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden.]

Nächster Schritt

[PLACEHOLDER: Konkreter nächster Arbeitsschritt.]

06.08.2026 – Datensatz geladen und technische EDA begonnen

Zusammenfassung

Der Santander-Datensatz wurde über OpenML (Datensatz-ID 45566) geladen und als lokale CSV-Datei für die weitere Analyse im Ordner `data` abgelegt. Parallel wurde das Notebook `EDA/01_Datensatz_Einfuehrung.ipynb` erstellt und vollständig ausgeführt.

Arbeitsschritte

- Datensatz mit `sklearn.datasets.fetch_openml(data_id=45566, as_frame=True)` bezogen.
- Die Rohdaten unverändert als `data/santander_customer_transaction_prediction.csv` gespeichert.
- Eine Daten-README mit Quelle, OpenML-ID, Downloadmethode und Download-Datum ergänzt.
- Das EDA-Notebook mit Ladepfad, Form, Speicherbedarf, Spaltennamen, Datentypen, fehlenden Werten und Zielklassenverteilung ausgeführt.

Ergebnis/Erkenntnis

Der Datensatz enthält 200.000 Zeilen und 201 Spalten. Davon sind 200 Spalten numerische Merkmale vom Typ `float64`; die Zielvariable `target` ist boolesch. Es wurden insgesamt 0 fehlende Zellen, 0 Spalten mit fehlenden Werten und 0 Zeilen mit fehlenden Werten festgestellt. Die Zielvariable umfasst 179.902 negative (89,951 %) und 20.098 positive (10,049 %) Fälle. Der eingelesene DataFrame benötigt tiefen Speicherbedarf von rund 305,37 MiB; die CSV-Datei

ist rund 292,06 MiB groß (306.200.605 Bytes). Die Merkmalsnamen sind anonymisiert und reichen von `var_0` bis `var_199`; die letzte Spalte ist `target`.

Entscheidung und Begründung

Die Rohdaten werden wegen ihrer Größe nicht versioniert, sondern über die dokumentierte OpenML-ID reproduzierbar beschafft. Im Notebook wird zunächst nur geladen und beschrieben; Transformationen werden erst nach dieser technischen Bestandsaufnahme und nachvollziehbar in weiteren EDA-Schritten vorgenommen.

Verworfenе Ansätze/Schwierigkeiten

Ein direkter Download einer nicht dokumentierten externen Datei wurde nicht verwendet. Stattdessen wurde OpenML als reproduzierbare Quelle gewählt. Die große CSV-Datei ist für Git ungeeignet und bleibt deshalb lokal. Die Merkmalsnamen enthalten keine fachliche Semantik; ihre Bedeutung muss über die Aufgabenbeschreibung und die statistische EDA erschlossen werden.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung. Die technische Datensatzprüfung wurde als erster EDA-Schritt vor Visualisierungen und Modellierung durchgeführt.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Duplikate, konstante bzw. nahezu konstante Merkmale, Verteilungen, Ausreißer und Zusammenhänge mit der unausgeglichenen Zielvariable untersuchen.

06.08.2026 – Deskriptive Statistik, Korrelation und Normalisierung

Zusammenfassung

Die technische EDA wurde um die vollständige deskriptive Statistik aller 201 Spalten, eine Korrelationsmatrix, eine Prüfung auf Kategorikalität bzw. Wertkonzentration, eine Negativwertanalyse und eine Min-Max-Normalisierung erweitert.

Arbeitsschritte

- Für jede Spalte Minimum, Maximum, Mittelwert, Median, Varianz, Standardabweichung, Skewness und Kurtosis berechnet. Das boolesche `target` wurde für diese Kennzahlen zusätzlich als 0/1 numerisch betrachtet.
- Eine Pearson-Korrelationsmatrix der Form 201×201 erstellt und die stärksten absoluten Zusammenhänge ausgegeben.
- Datentypen, Kardinalität, dominante Einzelwerte und negative Werte je Feature geprüft.
- Die 200 Features mit Min-Max auf das Intervall $[0,1]$ transformiert; `target` blieb unverändert.

Ergebnis/Erkenntnis

Alle 200 Features sind vom Typ `float64`; ausschließlich `target` ist boolesch. 131 von 200 Features (65,5 %) enthalten mindestens einen negativen Wert, 69 Features enthalten keine negativen Werte. Es gibt 0 konstante Features. Kein Feature hat maximal 20 verschiedene Werte oder eine Dominanz eines einzelnen Wertes von mindestens 90 %. Damit zeigen die

Features keinen Hinweis auf klassische kategorische Variablen; das boolesche `target` ist die einzige kategoriale Spalte. Die Korrelationsmatrix hat die Form 201×201 ; die stärksten linearen Zusammenhänge mit dem Ziel zeigen `var_81` ($r=-0,080917$), `var_139` ($r=-0,074080$), `var_12` ($r=-0,069489$) und `var_6` ($r=0,066731$). Nach der Normalisierung liegen globales Minimum und Maximum der Featurematrix bei 0 bzw. 1.

Entscheidung und Begründung

Die Bool-Variable wird als Zielvariable behandelt und nicht als gewöhnliches kontinuierliches Feature normalisiert. Für die Merkmale ist Min-Max eine nachvollziehbare erste Skalierung, weil dadurch alle unterschiedlichen Wertebereiche vergleichbar werden. Die Rohdaten bleiben unverändert; `X_minmax` wird nur reproduzierbar im Notebook erzeugt.

Verworfenе Ansätze/Schwierigkeiten

Eine vollständige 201×201 Matrix ist als Tabelle schwer lesbar. Deshalb wird sie vollständig als Objekt `correlation_matrix` gespeichert und zusätzlich über die stärksten Korrelationspaare zusammengefasst. Die anonymisierten Feature-Namen erlauben keine fachliche Interpretation einzelner Variablen; die Korrelationswerte sind daher zunächst nur deskriptiv. Die Notebook-Ausführung dauerte wegen des großen Datensatzes und der Matrixberechnung rund zwei Minuten.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung. Die Normalisierung wurde noch nicht als neue Datei gespeichert und nicht auf die Zielvariable angewendet.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Verteilungen und Ausreißer gezielt visualisieren, stark schiefe Merkmale prüfen und die Feature-Ziel-Zusammenhänge im Kontext der Klassenimbalance bewerten.

06.08.2026 – Visualisierung, PCA, t-SNE und Clustering

Zusammenfassung

Die EDA wurde um grafische Darstellungen und eine erste unüberwachte Strukturanalyse ergänzt. Erstellt wurden eine Korrelations-Heatmap, Boxplots der normalisierten Features und Zeilen, Verteilungsübersichten, Q-Q-Plots sowie PCA- und t-SNE-Projektionen mit K-Means- und DBSCAN-Clustern.

Arbeitsschritte

- Korrelationsmatrix der 200 Features als Heatmap visualisiert.
- Boxplots aller normalisierten Features und Boxplots von 100 zufällig ausgewählten Zeilen erstellt; zusätzlich Verteilung der Feature-Mittelwerte und eine Stichprobe aller Werte geplottet.
- Q-Q-Plots für `var_0`, `var_68`, `var_81` und `var_199` gegen die Normalverteilung erzeugt.
- PCA auf zwei Dimensionen für die gesamte normalisierte Featurematrix berechnet.
- Für t-SNE eine reproduzierbare Stichprobe von 5.000 Zeilen verwendet und zuvor auf 50 PCA- Komponenten reduziert.

- Auf beiden 2D-Embeddings K-Means mit $k = 2$ und DBSCAN angewandt. `target` wurde ausschließlich als Label verwendet und nachträglich mit ARI/NMI verglichen.

Ergebnis/Erkenntnis

Die ersten beiden PCA-Komponenten erklären nur 0,7503 % bzw. 0,6860 % der Varianz, zusammen rund 1,44 %. K-Means erzeugte in PCA zwei Cluster mit 2.726 und 2.274 Punkten, in t-SNE zwei Cluster mit 2.479 und 2.521 Punkten. Die Übereinstimmung mit `target` ist jeweils sehr gering: PCA-K-Means ARI=-0,0016 und NMI=0,0004; t-SNE-K-Means ARI=0,0008 und NMI=0,0015. DBSCAN erzeugte mit der ersten Parametrisierung auf PCA einen großen Cluster mit 4.999 Punkten und einen Ausreißer; auf t-SNE wurden alle 5.000 Punkte einem Cluster zugeordnet. Die DBSCAN-Übereinstimmung mit dem Target war entsprechend praktisch null.

Entscheidung und Begründung

Die Stichprobe von 5.000 Zeilen wurde wegen der hohen Rechenkosten von t-SNE und DBSCAN gewählt; der Zufallszustand 42 macht die Darstellung reproduzierbar. PCA und t-SNE werden als explorative Visualisierung behandelt, nicht als Beweis für fachlich sinnvolle Cluster. Die sehr geringe PCA-Varianz und die niedrigen ARI/NMI-Werte sprechen gegen eine klare zweidimensionale Trennung nach `target`.

Verworfenе Ansätze/Schwierigkeiten

Eine direkte t-SNE-Berechnung auf allen 200.000 Zeilen wurde wegen unverhältnismäßiger Laufzeit nicht verwendet. DBSCAN mit `eps = 0,5` auf den standardisierten 2D-Embeddings war zu wenig trennscharf und wird deshalb nicht als finale Clusterlösung interpretiert. Die Q-Q-Plots zeigen nur vier repräsentative Features; eine vollständige Verteilungsbewertung aller 200 Features bleibt ein nächster Analyseschritt.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung. Die Clusterverfahren wurden auf einer dokumentierten Stichprobe ausgeführt; die Zielvariable wurde nicht als Feature verwendet.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

DBSCAN-Parameter und Clusteranzahl systematisch sensitivitätsprüfen, weitere Verteilungen visualisieren und mögliche Ausreißer bzw. stark schiefe Features untersuchen.

06.08.2026 – Erweiterte Label-/Feature-EDA

Zusammenfassung

Die EDA wurde klar in Label und Features getrennt. Für alle 200 Features wurden Klassenimbalance, gruppierte Verteilungen, Mittelwert- und Medianunterschiede sowie label-konditionierte Feature-Feature-Korrelationen untersucht und visualisiert.

Arbeitsschritte

- Featurematrix X mit 200 Spalten und Labelvektor $y = \text{target}$ separat definiert.
- Klassenhäufigkeiten und Klassenanteile als Balkendiagramm und Kreisdiagramm dargestellt.
- Für jedes Feature Mittelwert, Median und Standardabweichung je Labelgruppe berechnet.

- Absolute und relative Mittelwertdifferenzen sowie Cohen's d als standardisierte Effektgröße bestimmt und für alle 200 Features geplottet.
- Alle Features in zehn gruppierten Boxplot-Seiten mit jeweils `target=False` und `target=True` verglichen; die zwölf stärksten Features zusätzlich als Violinplots.
- Je Labelgruppe eine 200×200 -Korrelationsmatrix berechnet und die Differenz $\text{corr}(True) - \text{corr}(False)$ als Heatmap und Rangliste dargestellt.

Ergebnis/Erkenntnis

Die Labelverteilung bleibt mit 179.902 False (89,951 %) und 20.098 True (10,049 %) deutlich unausgeglichen. Die größten positiven standardisierten Mittelwertdifferenzen zeigen `var_6` ($d = 0,215926$), `var_110` ($d = 0,205989$), `var_53` ($d = 0,204101$), `var_26` ($d = 0,199796$) und `var_22` ($d = 0,194818$). Die größten negativen Differenzen zeigen `var_81` ($d = -0,255463$), `var_139` ($d = -0,237684$), `var_12` ($d = -0,221911$), `var_146` ($d = -0,204394$) und `var_76` ($d = -0,199939$). Die stärkste Veränderung einer Feature-Feature-Korrelation beträgt nur rund 0,031455 (Paar `var_62/var_173`); weitere starke Änderungen liegen ebenfalls nur knapp über 0,03. Die Korrelationen zwischen Features verändern sich durch das Label somit in dieser ersten Auswertung nur schwach.

Entscheidung und Begründung

Cohen's d wird zur Rangordnung verwendet, weil rohe Mittelwertdifferenzen wegen der unterschiedlichen Feature-Skalen nicht direkt vergleichbar sind. Die label-konditionierten Korrelationsmatrizen werden getrennt von der ursprünglichen Matrix analysiert, weil eine Korrelation des konstanten Labels innerhalb einer einzelnen Gruppe nicht definiert wäre. Die Rohdaten und die Labeltrennung bleiben unverändert.

Verworfenе Ansätze/Schwierigkeiten

Die gruppierten Boxplots werden aus Rechen- und Darstellungsgründen mit 2.000 zufällig gezogenen Zeilen pro Klasse geplottet; alle Tabellen und Effektgrößen basieren weiterhin auf dem vollständigen Datensatz. Eine sichtbare Verteilungsdifferenz ist nicht automatisch kausal und muss wegen der 200 parallelen Tests vorsichtig interpretiert werden. Die Korrelationsdifferenzen sind klein und werden deshalb nicht als starker Beleg für labelabhängige Abhängigkeiten bewertet.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung. Das Label wurde in keinem Schritt als erklärendes Feature verwendet.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Mehrfachtestproblematik und statistische Signifikanz der Unterschiede prüfen, Effektgrößen mit Verteilungen und Ausreißern verbinden und die Featureauswahl für die Modellierung vorbereiten.

06.08.2026 – PCA-/t-SNE-Labelansichten und korrigierte Korrelations-Heatmaps

Zusammenfassung

Die Dimensionsreduktionsgrafiken wurden nach den beiden Labelwerten getrennt. Zusätzlich wurde die Diagonale aus den Korrelations-Heatmaps maskiert, da sie nur die Selbstkorrelation jedes Features zeigt und die Interpretation der übrigen Zusammenhänge verfälscht.

Arbeitsschritte

- Separate PCA-Abbildungen für ausschließlich `target=0` und ausschließlich `target=1` erzeugt.
- Separate t-SNE-Abbildungen für ausschließlich `target=0` und ausschließlich `target=1` erzeugt.
- Für alle vier Bilder identische Achsenbereiche gesetzt, damit die räumliche Verteilung zwischen den Labelgruppen direkt vergleichbar bleibt.
- Kontrastreiche Farben verwendet: Blau für Label 0 und Rot für Label 1.
- Die Diagonalen der globalen sowie der label-konditionierten Korrelations-Heatmaps mit Masken ausgeblendet; die Korrelationsrangliste nutzte bereits nur das obere Dreieck.
- Den PCA-/t-SNE-Abschnitt als eigene Visualisierungs- und Clustering-Gruppe kenntlich gemacht.

Ergebnis/Erkenntnis

Die vier neuen Labelansichten wurden mit der reproduzierbaren 5.000-Zeilen-Stichprobe erstellt. Dadurch sind Unterschiede in der Punktdichte und räumlichen Lage zwischen den Labelgruppen sichtbar, ohne dass die jeweils andere Klasse die Darstellung überlagert. Die Heatmaps zeigen nach der Maskierung ausschließlich Beziehungen zwischen verschiedenen Features.

Entscheidung und Begründung

Die getrennte Darstellung wurde gewählt, weil eine gemeinsame Farbskala die seltenere positive Klasse visuell überdecken kann. Identische Achsen sind für einen fairen Vergleich wichtiger als eine jeweils automatisch optimierte Ansicht. Die Diagonale wird nicht durch Null ersetzt, sondern als fehlend maskiert, damit sie nicht als künstlicher Wert in die Farbskala eingeht.

Verworfenе Ansätze/Schwierigkeiten

Eine gemeinsame Target-Abbildung bleibt als ältere Übersicht im Notebook erhalten, dient aber nicht mehr als primäre Labeldarstellung. Die Dimensionsreduktion basiert weiterhin auf einer Stichprobe für t-SNE; daraus dürfen keine Aussagen über exakte Häufigkeiten im vollständigen Datensatz abgeleitet werden.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung; es handelt sich um eine Darstellungs- und Interpretationsverbesserung.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Die getrennten Ansichten mit den Gruppenverteilungen, Effektgrößen und label-konditionierten Korrelationen zusammenführen und auffällige Features für die Modellierung priorisieren.

06.08.2026 – Skalenanpassung und direkter PCA-/t-SNE-Vergleich

Zusammenfassung

Die Skalen der Korrelations- und Gruppenmittelwert-Heatmaps wurden auf die tatsächlich beobachteten Wertebereiche angepasst. Zusätzlich wurden PCA und t-SNE jeweils in einer

gemeinsamen Dreifachansicht mit nur Label 0, nur Label 1 und beiden Labels zusammengeführt.

Arbeitsschritte

- Für die globale Feature-Korrelationsmatrix die Off-Diagonal-Minima und -Maxima als Farbgrenzen verwendet; die Diagonale bleibt maskiert.
- Für die label-konditionierten Matrizen eine gemeinsame Skala für True/False und eine separate beobachtete Skala für die Differenzmatrix verwendet.
- Die standardisierten Gruppenmittelwerte ebenfalls mit empirischem Minimum und Maximum skaliert.
- Je eine 3-Panel-Grafik für PCA und t-SNE mit identischen Achsen erstellt: nur `target=0`, nur `target=1`, beide gemeinsam.
- Die Top-Rangliste der label-bedingten Korrelationsänderungen um die Einzelwerte `corr_false` und `corr_true` ergänzt; zusätzlich werden Differenz und absolute Differenz ausgegeben und geplottet.

Ergebnis/Erkenntnis

Das stärkste Korrelationsänderungspaar `var_62/var_173` weist innerhalb `target=False` $r = 0,003212$ und innerhalb `target=True` $r = -0,028243$ auf. Die Differenz beträgt $-0,031455$. Damit ist der direkte Vergleich möglich; die absolute Änderung bleibt dennoch klein. Die neuen PCA-/t-SNE- Dreifachansichten machen sichtbar, ob eine scheinbare Labeltrennung nur durch die gemeinsame Darstellung oder tatsächlich durch räumlich getrennte Punktwolken entsteht.

Entscheidung und Begründung

Eine gemeinsame Farbskala ist für True/False notwendig, wenn die beiden label-konditionierten Matrizen direkt verglichen werden sollen. Die Differenzmatrix erhält eine eigene Skala, weil ihre Werte deutlich kleiner sind. Für PCA und t-SNE wurden gleiche Achsenbereiche pro Methode beibehalten; dadurch wird der Vergleich nicht durch automatische Achsenanpassung verfälscht.

Verworfenе Ansätze/Schwierigkeiten

Die feste Skala $[-1, 1]$ wurde für die Visualisierung verworfen, weil die tatsächlich beobachteten Korrelationen wesentlich kleiner sind und dadurch kaum Kontrast zeigen. Die empirische Skala verbessert die Lesbarkeit, ist aber bei Vergleichen zwischen unterschiedlichen Matrizen nur zusammen mit der dokumentierten gemeinsamen Skala interpretierbar.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung; die Änderungen betreffen Skalierung, Maskierung und Anordnung der bereits berechneten Ergebnisse.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Die nun besser lesbaren Unterschiede mit Effektgrößen, Verteilungen und statistischer Absicherung zusammenführen.

06.08.2026 – Interpretierbarkeit der erweiterten EDA-Plots verbessert

Zusammenfassung

Die erweiterten EDA-Grafiken wurden auf eine präzisere und kompaktere Interpretation angepasst. Beschriftungen erklären nun, ob Mittelwerte oder Pearson-Korrelationen dargestellt werden; die wichtigsten Verteilungsbeispiele und Korrelationsänderungen sind gezielt sortiert.

Arbeitsschritte

- Die Gruppenmittelwertgrafik in eine Darstellung der Abweichungen der Gruppenmittelwerte mittels Cohen's d und eine signiert log1p-transformierte Heatmap überführt.
- Die Bedeutung der standardisierten Gruppenmittelwerte ergänzt: Gruppenmittelwert geteilt durch gepoolte Standardabweichung; das Vorzeichen zeigt die Richtung der Abweichung.
- Die Verteilungsplots auf zehn Beispiele reduziert: fünf größte positive und fünf größte negative Cohen's- d -Effekte.
- Den Korrelationsplot als Pearson-Korrelationen je Labelgruppe beschriftet und die zwölf Paare nach absoluter label-bedingter Differenz absteigend geordnet.

Ergebnis/Erkenntnis

Die log1p-Transformation komprimiert große standardisierte Mittelwerte, behält aber positive und negative Richtungen durch die signierte Form bei. Die zehn ausgewählten Box- und Violinplots sind dadurch direkt mit der Effektgrößenrangliste verknüpft. Der Korrelationsvergleich zeigt weiterhin pro Featurepaar separat `corr_false`, `corr_true`, die Differenz und die absolute Differenz.

Entscheidung und Begründung

Die vollständige statistische Tabelle bleibt erhalten, während die Grafik auf die interpretierbarsten zehn Beispiele fokussiert wird. Eine empirische Farbskala zwischen beobachtetem Minimum und Maximum ist informativer als eine feste $[-1, 1]$ -Skala, sofern die gemeinsame Skala bei direkten Matrixvergleichen dokumentiert bleibt.

Verworfenе Ansätze/Schwierigkeiten

Die Darstellung aller 200 gruppierten Boxplots wurde für diesen Abschnitt verworfen, weil sie die zentralen Unterschiede schwer erkennbar macht. Die logarithmische Transformation darf nicht als Änderung der Rohdaten missverstanden werden; sie betrifft ausschließlich die Darstellung der standardisierten Gruppenmittelwerte.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung; es wurden ausschließlich Darstellung, Sortierung und Beschriftung verbessert.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Die zehn auffälligsten Features mit Signifikanztests, Konfidenzintervallen und möglichen Mehrfachtestkorrekturen weiter untersuchen.

06.08.2026 – Korrelationsbasierte Featureauswahl und erneute Dimensionsreduktion

Zusammenfassung

Da die ursprüngliche PCA-/t-SNE-Darstellung keine klare Trennung der Labelgruppen zeigte, wurde die Dimensionsreduktion mit 14 gezielt ausgewählten Features wiederholt. Die Auswahl basiert auf der signierten Zeilensumme der Differenzmatrix `corr_true - corr_false`. Zusätzlich wurde die globale Korrelationsmatrix nach der Summe der absoluten Off-Diagonal-Korrelationen sortiert.

Arbeitsschritte

- Für jedes Feature die signierte Summe seiner label-bedingten Korrelationsänderungen berechnet; die Diagonale wurde ausgeschlossen.
- Sieben Features mit den größten positiven Scores und sieben mit den größten negativen Scores ausgewählt.
- Die ausgewählten Features auf Basis der bestehenden Min-Max-Normalisierung verwendet und die Zielvariable weiterhin ausschließlich als Label behandelt.
- PCA für alle 200.000 Zeilen und t-SNE für eine reproduzierbare Stichprobe von 5.000 Zeilen mit den 14 Features berechnet.
- K-Means mit $k = 2$ und DBSCAN auf beiden neuen Embeddings ausgeführt.
- Labelvergleichsbilder für PCA und t-SNE sowie eine nach absoluter Korrelationssumme sortierte Korrelations-Heatmap erstellt.

Ergebnis/Erkenntnis

Die ausgewählten positiven Features sind `var_161`, `var_188`, `var_177`, `var_123`, `var_84`, `var_63` und `var_7`. Die ausgewählten negativen Features sind `var_19`, `var_176`, `var_189`, `var_184`, `var_194`, `var_69` und `var_169`. Die ersten beiden PCA-Komponenten erklären zusammen 17,1223 % der Varianz. K-Means zeigte weiterhin praktisch keine Übereinstimmung mit dem Label: PCA ARI=-0,0000, NMI=0,0001; t-SNE ARI=-0,0001, NMI=0,0009. DBSCAN bildete in beiden Embeddings nur einen Cluster. Die Dimensionsreduktion verbessert damit die erklärte PCA-Varianz deutlich gegenüber der 200-Feature-Baseline, erzeugt aber noch keine belastbare Labeltrennung.

Entscheidung und Begründung

Die mathematische Zielgröße $2\log_2(200) = 15,29$ wurde als symmetrische Auswahl von 7 positiven plus 7 negativen Features umgesetzt. Die signierte Zeilensumme wurde als Feature-Ranking verwendet, weil sie die Richtung der gesamten Korrelationsänderung berücksichtigt. Die absolute Korrelationssumme dient separat dazu, die Korrelationsmatrix nach den insgesamt am stärksten vernetzten Features zu ordnen.

Verworfenе Ansätze/Schwierigkeiten

Eine Auswahl nach einzelnen Extrempaaren wurde nicht verwendet, da dabei die übrigen Korrelationen eines Features unberücksichtigt bleiben würden. Eine absolute Zeilensumme wurde ebenfalls nicht als Hauptkriterium gewählt, weil sie die Richtung der label-bedingten Veränderung verliert. Die neue t-SNE-Ausführung dauerte wegen der rechenintensiven Dimensionsreduktion mehrere Minuten.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung. Die bisherige Analyse bleibt als Baseline erhalten; die neue Featureauswahl und die neuen Grafiken wurden separat gespeichert.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Die ausgewählten Features mit überwachten Modellen prüfen und untersuchen, ob die fehlende 2D-Trennung durch die Projektion oder durch tatsächlich geringe Labelinformation verursacht wird.

14.08.2026 – Ausgeglichene Labelgruppen und methodischer EDA-Ausblick

Zusammenfassung

Die label-konditionierte Korrelationsanalyse wurde zusätzlich mit einem reproduzierbaren Verhältnis von True:False = 1:1 durchgeführt. Dafür wurden alle 20.098 True-Zeilen beibehalten und mit `random_state=42` ohne Zurücklegen genau 20.098 False-Zeilen gezogen. Die Zielvariable blieb aus allen Korrelationsmatrizen ausgeschlossen; die Diagonale wurde weiterhin maskiert.

Durchgeführte Analysen

Für die balancierte Stichprobe wurden die False-, True- und Differenz-Korrelationsmatrix mit empirischen Skalen visualisiert. Zusätzlich wurden die Korrelationsdifferenzen und die absoluten Korrelations-Zeilensummen mit der unausgeglichene Baseline verglichen. Die Baseline-Grafiken wurden nicht überschrieben; neue Abbildungen liegen unter `EDA/assets/`.

Ergebnis/Erkenntnis

Die 1:1-Auswertung ermöglicht einen direkteren Gruppenvergleich, ist als Undersampling jedoch selbst stichprobenabhängig. Unterschiede zwischen Baseline und 1:1-Analyse dürfen deshalb nicht ohne Stabilitätsprüfung als echte Populationseffekte interpretiert werden. Für die nächsten Schritte sind mehrere Seeds und Bootstrap-Konfidenzintervalle vorgesehen.

Zusätzliche Violinplots

Ergänzend zu den zehn bestehenden repräsentativen Violinplots wurden fünf Features dynamisch über `abs(cohens_d).nsmallest(5)` ausgewählt. Jeder Plot zeigt die Verteilungen von False und True, Median und Quartile sowie Feature, Cohen's d und Gruppenmittelwerte. Die Auswahl und Grafik werden separat gespeichert.

PCA/t-SNE-Dokumentation

Die Notebooktexte stellen nun ausdrücklich klar, dass die Eingabefeatures Min-Max-normalisiert im Intervall $[0,1]$ liegen und `target` nicht als Feature verwendet wird. PCA wird als lineare, varianzmaximierende Projektion beschrieben; t-SNE als nichtlineare, lokale Nachbarschaftsprojektion mit 5.000er Stichprobe und parameter-/seedabhängigem Ergebnis. Überlappung in zwei Dimensionen beweist keinen Informationsverlust, und eine sichtbare Trennung wäre kein Beweis für robuste Modellierbarkeit.

Ausblick

Als nächste EDA-Schritte wurden Stabilitätsanalysen, Bootstrap-Intervalle, Multiple-Testing-Korrektur, Signifikanztests und Effektgrößen, Mutual Information, Ausreißer und Heavy Tails, Redundanz- und Varianzanalysen, Vergleiche verschiedener Skalierungen, PCA-Scree-Plot, Ranglistenstabilität sowie anschließend ein überwachtes Baseline-Modell mit ROC-AUC, PR-AUC, Balanced Accuracy, Recall, Precision und F1 dokumentiert. Besonders relevant bleiben die starke Klassenimbalance, anonymisierte kontinuierliche Features, negative Rohwerte, geringe 2D-PCA-Varianz und schwache label-bedingte Korrelationsänderungen.

Entscheidung und Begründung

Das 1:1-Verhältnis wurde durch False-Undersampling umgesetzt, weil alle seltenen True-Beobachtungen erhalten bleiben und der Vergleich dadurch nicht von der großen False-Gruppe dominiert wird. Die ursprüngliche unausgeglichene Analyse bleibt als Baseline erhalten.

Verworfenе Ansätze/Schwierigkeiten

Eine einzelne balancierte Stichprobe reicht nicht aus, um die Stabilität der Korrelationen zu garantieren. Außerdem bleiben PCA und t-SNE bewusst explorativ; ihre 2D-Darstellungen werden nicht als endgültiger Nachweis für oder gegen Modellierbarkeit gewertet.

Abweichung vom vereinbarten Vorgehen

Keine inhaltliche Abweichung. Die neuen Berechnungen, Grafiken und Erläuterungen wurden zusätzlich zu den vorhandenen Baseline-Analysen ergänzt.

Gruppentreffen

Kein inhaltliches Gruppentreffen dokumentiert.

Zeitaufwand

[PLACEHOLDER: Minuten/Stunden ergänzen]

Nächster Schritt

Stabilität der 1:1-Ergebnisse über mehrere Seeds und Bootstrap-Stichproben prüfen und danach einen überwachten Baseline-Klassifikator mit Imbalance-Metriken trainieren.

E Laufende Methodik- und Entscheidungsübersicht

Diese Übersicht wird parallel zum Logbuch aktualisiert. Sie verhindert, dass wichtige Entscheidungen nur im Fließtext verborgen bleiben.

Bereich	Aktueller Stand	Begründung/Beleg
Datenzugang	OpenML ID 45566	Lokale CSV, geladen am 06.08.2026; Quelle und Download sind in data/README.md dokumentiert.
Datentypen	200 × float64, 1 × bool	DataFrame-Speicherbedarf rund 305,37 MiB; technische Bestandsaufnahme im EDA-Notebook.
Fehlende Werte	Keine festgestellt	0 fehlende Zellen, 0 betroffene Spalten und 0 betroffene Zeilen; keine Imputation erforderlich.
Zielvariable	target, boolesch	179.902 False (89,951 %) und 20.098 True (10,049 %); Klassenungleichgewicht bei Metrik und Split beachten.
Train-Test-Aufteilung	[PLACEHOLDER: offen]	[PLACEHOLDER: Zeitpunkt und Begründung]
Metrik(en)	[PLACEHOLDER: offen]	[PLACEHOLDER: Warum passend für die Aufgabe?]
Modelle	[PLACEHOLDER: offen]	[PLACEHOLDER: Vergleich und Auswahl]
Feature Engineering	[PLACEHOLDER: offen]	[PLACEHOLDER: getestete Varianten]

F Offene Fragen und Risiken

- [PLACEHOLDER: Welche genaue persönliche Forschungsfrage wird verfolgt?]
- [PLACEHOLDER: Wie wird die Gruppenarbeit aufgeteilt?]
- [PLACEHOLDER: Welche Metrik ist für die unausgeglichene Zielvariable sachgerecht?]
- [PLACEHOLDER: Wie groß ist der Datensatz und welche Speicherstrategie ist erforderlich?]
- [PLACEHOLDER: Welche Grenzen der Aussagekraft müssen später diskutiert werden?]

G Hinweise für die spätere Zusammenfassung

Bei der späteren Verdichtung des Logbuchs müssen Fragestellung, Methodenwahl, Ergebnisse, Schwierigkeiten/Grenzen und Ausblick klar erkennbar sein. Für Abbildungen und Tabellen werden Nummer, kurze Caption, Textreferenz und ein prägnanter Take-away ergänzt. Die ausführliche Nachvollziehbarkeit bleibt in diesem Logbuch erhalten.

H Abschluss-Checkliste

- Name, Gruppennummer, Thema und Gruppenmitglieder ergänzt
- Forschungsfrage und Ziel präzisiert
- Logbuch chronologisch und zeitnah geführt
- Entscheidungen, verworfene Ansätze, Schwierigkeiten und Iterationen dokumentiert
- EDA-Erkenntnisse mit Modellentscheidungen verknüpft
- Modelle, Metriken, Pipelines, Learning Curves und Hyperparameter beschrieben
- Abbildungen/Tabellen nummeriert, beschriftet und interpretiert
- Gruppenmitglieder fair und konkret eingeschätzt
- Quellen, Softwareversionen und KI-Nutzung vollständig dokumentiert
- PDF kompiliert und nach dem vorgegebenen Schema benannt