
E-Portfolio

Santander Customer Transaction Prediction

Name	Cyprian Sawarzynski
Modul	Advanced Data Analytics / Scientific Programming and Data Analysis
Semester	Sommersemester 2026
Gruppennummer	138
Gruppenmitglieder	Tim Hebestreit (Gruppenleiter), Angeline Usanayo, Trong Cao
Sprecher/Gruppenleitung	Tim Hebestreit
Abgabetermin	01.09.2026

Inhaltsverzeichnis

1	Projektueberblick und persoenliche Fragestellung	2
1.1	Datensatz und Aufgabenstellung	2
1.2	Persoenliche Fragestellung	2
1.3	Ziel meines Arbeitsanteils	2
2	Individuelles Logbuch	2
2.1	Zweck und Fuehrungsregeln	2
2.2	Projekt- und Gruppenrahmen	3
2.3	Chronologische Eintraege	3
2.4	Laufende Methodik- und Entscheidungsuebersicht	7
2.5	Aktuelle offene Fragen und Risiken	8
2.6	Hinweise fuer die spaetere Zusammenfassung	8
3	Verdichtete Zusammenfassung der bisherigen Arbeit	9
3.1	Datenbasis und Datenqualitaet	9
3.2	Verteilungen, Gruppenunterschiede und statistische Absicherung	9
3.3	Abhaengigkeiten, Redundanz und nichtlineare Information	9
3.4	Skalierung und Dimensionsreduktion	10
3.5	Erste ueberwachte Referenz	10
3.6	Wichtigste methodische Entscheidungen und Korrekturen	12
3.7	Grenzen und naechster Schritt	12
4	Einschaetzung der Gruppenmitglieder	12
5	Quellen und Hilfsmittel	12
5.1	KI- und Tool-Transparenz	13
A	Offene Punkte vor der Abgabe	14

1 Projektueberblick und persoenliche Fragestellung

1.1 Datensatz und Aufgabenstellung

Das Gruppenprojekt behandelt den Datensatz *Santander Customer Transaction Prediction*. Die Daten stammen aus einer Kaggle Competition aus dem Jahr 2019. Auf Basis von 200 anonymisierten numerischen Merkmalen soll vorhergesagt werden, ob die Zielvariable `target` positiv ist.

- OpenML-Datensatz: ID 45566
- Kaggle: <https://www.kaggle.com/c/santander-customer-transaction-prediction>
- OpenML: <https://www.openml.org/search?type=data&status=active&id=45566>

1.2 Persoenliche Fragestellung

Mein bisheriger Schwerpunkt ist die Frage, **welche statistisch stabilen Unterschiede zwischen `target=False` und `target=True` in den anonymisierten Features erkennbar sind und welche Konsequenzen sich daraus fuer eine robuste Modellierung unter starker Klassenimbalance ergeben**. Dabei wird zwischen statistischer Signifikanz, praktischer Effektgroesse, linearer bzw. nichtlinearer Abhaengigkeit und Darstellungseffekten von Dimensionsreduktionsverfahren unterschieden.

1.3 Ziel meines Arbeitsanteils

Ziel meines bisherigen Arbeitsanteils ist eine nachvollziehbare EDA als Grundlage fuer die anschliessende Modellierung. Dazu gehoeren Datenqualitaet, Klassenverteilung, Featureverteilungen, Effektgroessen, Inferenz, Redundanz, Dimensionsreduktion, Stabilitaetspruefungen und eine erste ueberwachte Referenz. Die EDA soll begruenden, welche Modellierungsentscheidungen spaeter sinnvoll sind und welche Annahmen nicht durch die Daten gestuetzt werden.

2 Individuelles Logbuch

Das Logbuch ist eine separate Quelldatei, wird aber an dieser Stelle vollstaendig in das Portfolio eingebunden. Dadurch bleibt die chronologische Arbeitsdokumentation technisch getrennt und trotzdem Bestandteil des eigentlichen Portfolios. Die Datei `Logbuch_Santander_Cyp.tex` enthaelt ausschliesslich den Inhalt dieses Kapitels und wird nicht separat kompiliert.

2.1 Zweck und Fuehrungsregeln

Dieses Logbuch dokumentiert meinen individuellen Arbeitsprozess chronologisch. Es ist bewusst kein nachtraeglich geglaetteter Ergebnisbericht. Fachliche Ergebnisse werden im Portfolio thematisch verdichtet; hier bleiben auch Korrekturen, verworfene Ansaetze und Iterationen sichtbar.

Jeder neue Eintrag soll Datum, Titel, Arbeitsschritt, Ergebnis bzw. Erkenntnis, Entscheidung und Begrueundung, Schwierigkeiten oder verworfene Ansaetze sowie den naechsten Schritt enthalten. Zeitaufwand und Gruppentreffen werden nur eingetragen, wenn sie tatsaechlich nachvollziehbar sind. Fehlende persoenliche Angaben werden nicht nachtraeglich erfunden.

2.2 Projekt- und Gruppenrahmen

Thema	Santander Customer Transaction Prediction
Datensatz	OpenML ID 45566
Name	Cyprian Sawarzynski
Gruppennummer	138
Gruppenmitglieder	Tim Hebestreit (Gruppenleiter), Angeline Usanayo, Trong Cao
Sprecher/Gruppenleitung	Tim Hebestreit
Projektdeadline	01.09.2026
Individueller Workload-Richtwert	ca. 100 Stunden

2.3 Chronologische Eintraege

06.08.2026 Projektunterlagen und Projektauswahl

Zusammenfassung: Bewertungs- und Projektunterlagen wurden gelesen; Santander Customer Transaction Prediction wurde als Projekt festgelegt.

Arbeitsschritte: Bewertungshinweise und Santander-Aufgabenblatt gelesen; OpenML-ID 45566 sowie Kaggle-/OpenML-Quellen vorgemerkt.

Ergebnis/Erkenntnis: Es handelt sich um eine binaere Klassifikationsaufgabe; EDA-Erkenntnisse sollen spaeter nachvollziehbar mit Modellentscheidungen verbunden werden.

Entscheidung und Begrueendung: Fokus auf Santander entsprechend der Gruppenprojektauswahl und der klaren reproduzierbaren Datenreferenz.

Offene Punkte: Aufgabenverteilung, persoenliche Forschungsfrage, Modellstrategie und Rechenrahmen waren zu diesem Zeitpunkt noch zu klaeren.

Gruppentreffen: [NOCH AUSZUFUELLEN: nur ergaenzen, falls fuer diesen Arbeitsschritt ein Treffen stattfand]

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]

Naechster Schritt: E-Portfolio und Logbuch als Arbeitsgrundlage anlegen; anschliessend Daten technisch pruefen.

06.08.2026 E-Portfolio auf LaTeX umgestellt

Zusammenfassung: Das zunaechst als Notebook angelegte E-Portfolio wurde auf LaTeX umgestellt, um Layout und finale PDF-Ausgabe besser kontrollieren zu koennen.

Arbeitsschritte: Ordner E_Portfolio, Portfolio-Hauptdatei und separates Logbuch angelegt; Grundstruktur und Asset-Ordner vorbereitet; XeLaTeX-Kompilierung geprueft.

Entscheidung und Begrueendung: Portfolio und Logbuch bleiben getrennte Quelldateien: Das Logbuch bewahrt die Chronologie und wird direkt in Kapitel 2 des Portfolios eingebunden; das Portfolio verdichtet die Ergebnisse anschliessend thematisch.

Verworfenе Ansaetze/Schwierigkeiten: Notebook-/nbconvert-Ausgabe wurde wegen unzureichender PDF-Gestaltung verworfen; TinyTeX-Praeambel musste auf verfuegbare Pakete reduziert werden.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]

Naechster Schritt: Technische EDA beginnen.

06.08.2026**Datensatz geladen und technische EDA begonnen**

Arbeitsschritte: Datensatz mit `fetch_openml(data_id=45566, as_frame=True)` geladen; Rohdaten lokal als CSV abgelegt; Datenquelle dokumentiert; Notebook erstellt und ausgeführt.

Ergebnis/Erkenntnis: 200.000 Zeilen, 201 Spalten; 200 `float64`-Features und boolesches `target`; keine fehlenden Zellen. Zielklassen: 179.902 False (89,951 %) und 20.098 True (10,049 %). DataFrame ca. 305,37 MiB; CSV ca. 292,06 MiB.

Entscheidung und Begründung: Rohdaten werden wegen der Groesse nicht versioniert, sondern ueber OpenML reproduzierbar beschafft. Transformationen erfolgen erst nach technischer Bestandsaufnahme.

Verworfene Ansaetze/Schwierigkeiten: Nicht dokumentierte externe Downloadquellen wurden nicht verwendet; anonymisierte Features verhindern fachliche Semantik auf Variablenebene.

Zeitaufwand: **[NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]**

Naechster Schritt: Konstanz, Wertverteilungen, Ausreisser und Feature-Ziel-Zusammenhaenge untersuchen.

06.08.2026**Deskriptive Statistik, Korrelation und Normalisierung**

Arbeitsschritte: Minimum, Maximum, Mittelwert, Median, Varianz, Standardabweichung, Skewness und Kurtosis berechnet; Pearson-Korrelationsmatrix erstellt; Kardinalitaet, dominante Werte und negative Werte geprueft; Features Min-Max-normalisiert.

Ergebnis/Erkenntnis: 131 von 200 Features enthalten negative Werte; keine konstanten Features und keine klar kategorial wirkenden numerischen Features. Staerkste lineare Zielkorrelationen: `var_81` $r = -0,080917$, `var_139` $r = -0,074080$, `var_12` $r = -0,069489$, `var_6` $r = 0,066731$.

Entscheidung und Begründung: `target` wird nicht skaliert; Min-Max-Skalierung dient als reproduzierbare Vergleichsbasis fuer spaetere Projektionen.

Verworfene Ansaetze/Schwierigkeiten: Die vollstaendige Korrelationsmatrix ist als Tabelle nicht lesbar und wird daher visualisiert bzw. ueber Ranglisten zusammengefasst.

Zeitaufwand: **[NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]**

Naechster Schritt: Verteilungen und Ausreisser visualisieren und Klassenunterschiede untersuchen.

06.08.2026**Visualisierung, PCA, t-SNE und Clustering**

Arbeitsschritte: Korrelations-Heatmap, Boxplots, Verteilungsuebersichten und Q-Q-Plots erstellt; PCA auf zwei Dimensionen; t-SNE auf reproduzierbarer 5.000er Stichprobe nach PCA-Vorreduktion; K-Means und DBSCAN auf den 2D-Embeddings.

Ergebnis/Erkenntnis: PC1 erklart 0,7503 %, PC2 0,6860 %, zusammen ca. 1,44 %. K-Means und DBSCAN stimmen praktisch nicht mit dem Target ueberein; ARI/NMI liegen nahe null.

Entscheidung und Begründung: 2D-Projektionen und Cluster werden ausschliesslich explorativ interpretiert. t-SNE wird wegen Rechenaufwand nur auf einer dokumentierten Stichprobe ausgefuehrt.

Verworfene Ansaetze/Schwierigkeiten: t-SNE auf allen 200.000 Zeilen wurde wegen unverhaeltnismaessiger Laufzeit nicht verwendet; erste DBSCAN-Parametrisierung erzeugte keine sinnvolle Clusterstruktur.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]

Naechster Schritt: Label- und Feature-EDA gezielter trennen.

06.08.2026

Erweiterte Label-/Feature-EDA

Arbeitsschritte: Klassenverteilung visualisiert; klassenweise Mittelwerte, Mediane und Standardabweichungen berechnet; Cohen's d fuer alle Features bestimmt; Box-/Violinplots erstellt; label-konditionierte Korrelationsmatrizen verglichen.

Ergebnis/Erkenntnis: Groesste positive Cohen's- d -Werte: $\text{var}_6=0,215926$, $\text{var}_{110}=0,205989$, $\text{var}_{53}=0,204101$, $\text{var}_{26}=0,199796$, $\text{var}_{22}=0,194818$. Groesste negative: $\text{var}_{81}=-0,255463$, $\text{var}_{139}=-0,237684$, $\text{var}_{12}=-0,221911$, $\text{var}_{146}=-0,204394$, $\text{var}_{76}=-0,199939$. Staerkste label-bedingte Korrelationsaenderung nur ca. 0,031455.

Entscheidung und Begrueundung: Cohen's d wird fuer skalenunabhaengige Rangordnung verwendet; Target bleibt aus Feature-Feature-Korrelationen ausgeschlossen.

Verworfenе Ansaetze/Schwierigkeiten: Gruppierte Boxplots werden fuer die Darstellung subsampled; statistische Tabellen und Effektgroessen bleiben auf dem vollen Datensatz. Sichtbare Unterschiede werden nicht kausal interpretiert.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]

Naechster Schritt: Mehrfachtests und statistische Absicherung ergaenzen.

06.08.2026

PCA-/t-SNE-Labelansichten und korrigierte Korrelations-Heatmaps

Arbeitsschritte: PCA- und t-SNE-Ansichten getrennt nach Target erzeugt; identische Achsenbereiche verwendet; Korrelationsdiagonalen maskiert.

Ergebnis/Erkenntnis: Die getrennten Ansichten verbessern die Sichtbarkeit der seltenen positiven Klasse; Heatmaps zeigen nach Maskierung nur Beziehungen zwischen unterschiedlichen Features.

Entscheidung und Begrueundung: Identische Achsen und maskierte Diagonalen verhindern irrefuehrende visuelle Vergleiche.

Verworfenе Ansaetze/Schwierigkeiten: Gemeinsame Target-Abbildung bleibt als historische Uebersicht erhalten, ist aber nicht mehr primaere Darstellung.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]

Naechster Schritt: Labelansichten, Effektgroessen und Korrelationen gemeinsam interpretieren.

06.08.2026

Skalenanpassung und direkter PCA-/t-SNE-Vergleich

Arbeitsschritte: Empirische Farbgrenzen fuer Korrelationsdarstellungen verwendet; True/False-Matrizen mit gemeinsamer Skala, Differenzmatrix separat; PCA/t-SNE als 3-Panel-Vergleich aufgebaut.

Ergebnis/Erkenntnis: Beim Paar $\text{var}_{62}/\text{var}_{173}$: $r_{False} = 0,003212$, $r_{True} = -0,028243$, Differenz $-0,031455$. Numerisch bleibt die Aenderung klein.

Entscheidung und Begrueundung: Empirische Skalen erhoehen Lesbarkeit, muessen aber explizit dokumentiert werden, damit kleine Unterschiede nicht ueberinterpretiert werden.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]

Naechster Schritt: Darstellungen mit statistischer Absicherung verbinden.

06.08.2026 Interpretierbarkeit der erweiterten EDA-Plots verbessert

Arbeitsschritte: Gruppenmittelwertgrafik auf Cohen's d und signierte log1p-Darstellung umgestellt; Verteilungsplots auf zehn repräsentative Features reduziert; Korrelationsvergleich klarer beschriftet und sortiert.

Ergebnis/Erkenntnis: Die zentralen Effekte sind nun gezielter lesbar; vollständige statistische Tabellen bleiben erhalten.

Entscheidung und Begründung: Grafiken werden auf interpretierbare Beispiele reduziert, ohne numerische Vollständigkeit zu verlieren.

Verworfenе Ansätze/Schwierigkeiten: Darstellung aller 200 Boxplots in einem Ergebnisabschnitt wurde als zu unübersichtlich verworfen.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergänzen, falls belastbar nachvollziehbar]

Nächster Schritt: Signifikanztests, Konfidenzintervalle und Mehrfachtestkorrektur.

06.08.2026 Korrelationsbasierte Featureauswahl und erneute Dimensionsreduktion

Arbeitsschritte: 14 Features anhand der signierten Zeilensumme label-bedingter Korrelationsänderungen ausgewählt; PCA/t-SNE sowie K-Means/DBSCAN erneut ausgeführt.

Ergebnis/Erkenntnis: Ausgewählte positive Features: var_161, var_188, var_177, var_123, var_84, var_63, var_7; negative: var_19, var_176, var_189, var_184, var_194, var_69, var_169. Zwei PCA-Komponenten erklären nun 17,1223 %, aber Cluster-Übereinstimmung mit dem Target bleibt praktisch null.

Entscheidung und Begründung: Experiment bleibt als explorative Iteration dokumentiert, wird aber nicht als finale Featureauswahl gewertet.

Verworfenе Ansätze/Schwierigkeiten: Weder Extrempaare noch absolute Zeilensumme wurden als Hauptkriterium verwendet; das Experiment liefert keine belastbare Labeltrennung.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergänzen, falls belastbar nachvollziehbar]

Nächster Schritt: Mit überwachter Baseline prüfen, ob außerhalb der 2D-Projektion Vorhersageinformation vorhanden ist.

14.08.2026 Ausgeglichene Labelgruppen und methodischer EDA-Ausblick

Arbeitsschritte: Alle 20.098 True-Fälle mit 20.098 ohne Zurücklegen gezogenen False-Fällen (random_state=42) verglichen; balancierte Korrelationsanalyse und zusätzliche Violinplots erstellt; Grenzen von PCA/t-SNE expliziter dokumentiert.

Ergebnis/Erkenntnis: Eine 1:1-Auswertung erleichtert den Gruppenvergleich, ist aber selbst stichprobenabhängig. Eine einzelne balancierte Stichprobe reicht deshalb nicht für Stabilitätsaussagen.

Entscheidung und Begründung: Alle seltenen True-Fälle bleiben erhalten; False wird undersampled. Die natürliche Baseline bleibt parallel bestehen.

Nächster Schritt: Mehrere Seeds, Bootstrap, Inferenz, Mutual Information, Ausreisser-/Varianzanalyse, Redundanz, Skalierungsvergleich und überwachte Baseline.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergänzen, falls belastbar nachvollziehbar]

15.08.2026**Vollstaendige EDA-Erweiterung und Schlussfolgerung**

Arbeitsschritte: Fuenf 1:1-Seeds (42–46), Bootstrap-Intervalle mit 500 Wiederholungen und 5.000 Beobachtungen je Gruppe, Welch-Tests mit Benjamini-Hochberg-FDR, Mutual Information auf 50.000 Zeilen, IQR-Ausreisserquoten, Varianz-/IQR-Rankings, Redundanzpruefung ab $|r| \geq 0,8$, Skalierungsvergleich, PCA-Scree-Plot, Korrelationsranglistenstabilitaet und Logistic-Regression-Baseline umgesetzt.

Ergebnis/Erkenntnis: Cohen's- d -Ranglisten zwischen den fuenf 1:1-Stichproben: Spearman ca. 0,996. Nach FDR-Korrektur 181/200 Features signifikant. Erste 20 Min-Max-PCA-Komponenten: 12,988 % kumulierte Varianz. Keine Featurepaare mit $|r| \geq 0,8$. Logistic Regression: ROC-AUC 0,8599, PR-AUC 0,5004, Balanced Accuracy 0,7795, Recall 0,7749, Precision 0,2863, F1 0,4181.

Interpretation und Grenzen: Hohe Signifikanzzahl ist bei grosser Stichprobe nicht mit grossen Effekten gleichzusetzen; Effektgrossen und Konfidenzintervalle bleiben zentral. Mutual Information ist nicht kausal. PCA/t-SNE/Clustering sind explorativ. Logistic Regression ist eine Referenz, kein optimiertes Endmodell.

Entscheidung und Begrueendung: Die EDA wurde um Stabilitaets-, Inferenz- und Modellierungschecks erweitert, um robuste Muster von Projektionseffekten und Stichprobenartefakten zu trennen.

Verworfenene Ansaetze/Schwierigkeiten: Vollstaendige Notebookausfuehrung ist rechenintensiv; Bootstrap verwendet deshalb eine dokumentierte feste Stichprobengroesse pro Wiederholung.

Zeitaufwand: [NOCH AUSZUFUELLEN: nur ergaenzen, falls belastbar nachvollziehbar]

Naechster Schritt: Weitere ueberwachte Modelle mit Cross-Validation, geeigneten Imbalance-Strategien und Schwellenwertanalyse verglichen.

2.4 Laufende Methodik- und Entscheidunguebersicht

Bereich	Aktueller Stand	Begrueendung/Beleg
Datenzugang	OpenML ID 45566	Reproduzierbare Quelle; lokale Rohdaten werden nicht versioniert.
Datenqualitaet Zielvariable	Keine fehlenden Werte 89,951 % False / 10,049 % True	Keine Imputation erforderlich. Klassenimbalance muss in Training, Metriken und Schwellenwahl beruecksichtigt werden.
Skalierung	Min-Max fuer PCA/t-SNE/Clustering; Skalierungsvergleich durchgefuehrt	Target wird nicht skaliert und nicht als Eingabefeature verwendet.
Train-Test-Aufteilung	Stratifiziert 80:20 fuer die Logistic-Regression-Baseline	Erhaelt die Klassenanteile in beiden Splits.
Metriken	ROC-AUC, PR-AUC, Balanced Accuracy, Recall, Precision, F1	Kombination aus Ranking- und Schwellenmetriken fuer unausgeglichene Klassen.
Baseline-Modell	Logistic Regression mit <code>class_weight=balanced</code>	Erste ueberwachte Referenz; kein Endmodell.

Featureauswahl	Noch keine finale Auswahl	14-Feature-Variante war ein exploratives Experiment und wird nicht als finaler Selektionsschritt gewertet.
Hyperparameter	Finale Optimierung noch offen	Soll erst im systematischen Modellvergleich mit Cross-Validation erfolgen.

2.5 Aktuelle offene Fragen und Risiken

- Wie werden weitere Modelle und Imbalance-Strategien fair per Cross-Validation verglichen?
- Welche Schwellenwertstrategie ist fuer die Zielmetrik sinnvoll, insbesondere mit Blick auf Precision und Recall?
- Welche EDA-Entscheidungen duerfen in der Modellierungsphase nur innerhalb der Trainingsdaten wiederholt werden, um Data Leakage zu vermeiden?
- Wie robust sind rechenintensive Verfahren wie t-SNE und Bootstrap gegen Seeds, Stichprobengroesse und Parameterwahl?
- Die anonymisierten Features begrenzen fachliche Interpretation und Kausalitaetsaussagen.
- Zeitaufwaende, Gruppentreffen sowie KI-/Prompt-Nutzung muessen vor Abgabe anhand realer Aufzeichnungen vervollstaendigt werden.

2.6 Hinweise fuer die spaetere Zusammenfassung

Das Portfolio soll die EDA nicht chronologisch nacherzaehlen. Es verdichtet den Arbeitsprozess in eine fachliche Reihenfolge: Datenbasis und Datenqualitaet, Klassenimbalance, Gruppenunterschiede, Abhaengigkeiten und Redundanz, Dimensionsreduktion, ueberwachte Referenz, Grenzen und daraus abgeleitete Modellierungsentscheidungen. Die vollstaendige Chronologie bleibt ausschliesslich in diesem Logbuch.

3 Verdichtete Zusammenfassung der bisherigen Arbeit

3.1 Datenbasis und Datenqualitaet

Der Datensatz umfasst 200.000 Beobachtungen, 200 kontinuierliche `float64`-Features und die boolesche Zielvariable `target`. Fehlende Werte wurden nicht festgestellt. Die Zielvariable ist stark unausgeglichen: 179.902 Beobachtungen gehoeren zur negativen Klasse (89,951 %), 20.098 zur positiven Klasse (10,049 %). Die Features sind anonymisiert; eine inhaltlich-kausale Interpretation einzelner Variablen ist daher nicht moeglich.




Abbildung 1: Klassenverteilung des Santander-Datensatzes. Die starke Imbalance beeinflusst Stichprobendesign, Modelltraining und die Wahl geeigneter Evaluationsmetriken.

3.2 Verteilungen, Gruppenunterschiede und statistische Absicherung

Fuer alle Features wurden deskriptive Kennzahlen, Schiefe, Kurtosis sowie klassenweise Verteilungen untersucht. Zur skalennunabhaengigen Einordnung der Gruppenunterschiede wird Cohen's d verwendet. Zusaetzlich wurden Welch-Tests durchgefuehrt und die resultierenden p -Werte mit Benjamini-Hochberg-FDR korrigiert. Nach FDR-Korrektur waren 181 von 200 Features bei $\alpha = 0,05$ statistisch signifikant. Wegen der grossen Stichprobe wird dieses Ergebnis nicht isoliert interpretiert: Signifikanz wird gemeinsam mit Effektgroessen und Konfidenzintervallen betrachtet.

Die Stabilitaet der Effektgroessenranglisten wurde mit fuenf reproduzierbaren 1:1-Stichproben (Seeds 42 bis 46) geprueft. Die Ranglisten nach Cohen's d waren sehr stabil (Spearman ungefaehr 0,996). Damit sind die wichtigsten Gruppenunterschiede nicht lediglich ein Artefakt einer einzelnen balancierten Stichprobe.

3.3 Abhaengigkeiten, Redundanz und nichtlineare Information

Die Pearson-Korrelationen zwischen den Features sind insgesamt schwach. Es wurden keine Featurepaare mit $|r| \geq 0,8$ gefunden; damit gibt es bei diesem Schwellenwert keinen Hinweis auf starke lineare Redundanz. Label-konditionierte Korrelationsmatrizen wurden sowohl auf der natuerlichen Klassenverteilung als auch auf balancierten 1:1-Stichproben untersucht. Die Interpretation dieser Darstellungen wurde im Verlauf nachgeschaerft, weil empirisch enge Farbskalen kleine numerische Unterschiede visuell stark erscheinen lassen koennen.




Abbildung 2: Ausgewählte Violinplots zur Einordnung von Gruppenunterschieden. Die Visualisierung ergnzt die numerischen Effektgrößen; sie ersetzt keine statistische Absicherung.

Mutual Information wurde ergnzend verwendet, um mgliche nichtlineare Feature-Label-Zusammenhnge zu betrachten.

3.4 Skalierung und Dimensionsreduktion

Fr vergleichende Analysen wurden die Features reproduzierbar skaliert; PCA, t-SNE, K-Means und DBSCAN wurden auf Min-Max-normalisierten Features durchgefhrt. Die Zielvariable wurde nicht als Eingabefeature verwendet, sondern nur zur nachtraeglichen Visualisierung bzw. Bewertung.

Die ersten beiden PCA-Komponenten der vollstndigen 200-Feature-Darstellung erklren zusammen nur rund 1,44 % der Varianz. Auch der Scree-Plot zeigt, dass die globale Varianz breit ber viele Dimensionen verteilt ist: Die ersten 20 Min-Max-PCA-Komponenten erklren zusammen nur 12,988 %. Deshalb wird eine fehlende Trennung in zwei Dimensionen ausdrcklich nicht als Beweis fr fehlende prdiktive Information interpretiert. Gleiches gilt fr t-SNE, dessen Darstellung lokale Nachbarschaften betont und parameter- sowie seed-abhngig ist.

3.5 Erste ueberwachte Referenz

Als Plausibilittsprfung, ob trotz schwacher zweidimensionaler Trennung modellierbare Information vorhanden ist, wurde eine Logistic Regression mit `class_weight=balanced` und einem stratifizierten 80:20-Train-Test-Split verwendet. Die Baseline erreicht ROC-AUC 0,8599, PR-AUC 0,5004, Balanced Accuracy 0,7795, Recall 0,7749, Precision 0,2863 und F1 0,4181. Damit ist klar, dass die fehlende Clustertrennung in PCA/t-SNE nicht mit fehlender Vorhersageinformation gleichgesetzt werden darf. Gleichzeitig zeigt die niedrige Precision, dass die Klassenimbalance fr Schwellenwahl und Modellbewertung zentral bleibt.




Abbildung 3: PCA-Scree-Plot und kumulierte erklärte Varianz der Min-Max-normalisierten Features. Die geringe kumulierte Varianz weniger Komponenten begrenzt die Aussagekraft zweidimensionaler Projektionen.




Abbildung 4: ROC- und Precision-Recall-Kurven der Logistic-Regression-Baseline. Fuer die unausgeglichene Zielvariable ist insbesondere die Precision-Recall-Perspektive relevant.

3.6 Wichtigste methodische Entscheidungen und Korrekturen

Im Verlauf der EDA wurden mehrere Darstellungen und Interpretationen ueberarbeitet. Wesentliche Korrekturen waren die klare Trennung von Features und Label, die Maskierung der Korrelationsdiagonalen, der direkte Vergleich identischer Farb- und Achsenskalierungen, die Ergaenzung balancierter Stichproben und mehrerer Seeds sowie die explizite Einschraenkung der Aussagekraft von PCA, t-SNE und Clustering. Ein korrelationsbasiertes 14-Feature-Experiment wurde als explorativer Versuch dokumentiert, aber nicht als finale Featureauswahl uebernommen, weil es keine belastbare Labeltrennung erzeugte.

3.7 Grenzen und naechster Schritt

Die Feature-Namen sind anonymisiert und erlauben keine fachliche Kausalinterpretation. Undersampling, Bootstrap und Mutual Information besitzen eigene Stichproben- bzw. Schaetzunsicherheiten. Multiple Tests koennen bei grossen Stichproben auch sehr kleine Effekte als signifikant markieren. Dimensionsreduktions- und Clusterverfahren bleiben explorativ.

Der naechste fachliche Schritt ist deshalb kein weiterer Versuch, die EDA optisch zu optimieren, sondern ein sauberer Modellvergleich mit Cross-Validation, geeigneten Imbalance-Strategien, PR-AUC-orientierter Bewertung, Schwellenwertanalyse und nachvollziehbarer Hyperparameterwahl.

4 Einschaetzung der Gruppenmitglieder

Dieser vertrauliche Abschnitt soll auf realen Beobachtungen aus der Zusammenarbeit beruhen. Die Bewertung wird erst ergaenzt, wenn ausreichend belastbare eigene Beobachtungen vorliegen; automatische oder erfundene Einschaetzungen waeren hier nicht sachgerecht.

Tim Hebestreit

Staerke: [NOCH AUSZUFUELLEN: konkrete, beobachtete Staerke mit kurzer Begrueundung]

Entwicklungsfeld: [NOCH AUSZUFUELLEN: konkretes, beobachtetes Entwicklungsfeld mit kurzer Begrueundung]

Angeline Usanayo

Staerke: [NOCH AUSZUFUELLEN: konkrete, beobachtete Staerke mit kurzer Begrueundung]

Entwicklungsfeld: [NOCH AUSZUFUELLEN: konkretes, beobachtetes Entwicklungsfeld mit kurzer Begrueundung]

Trong Cao

Staerke: [NOCH AUSZUFUELLEN: konkrete, beobachtete Staerke mit kurzer Begrueundung]

Entwicklungsfeld: [NOCH AUSZUFUELLEN: konkretes, beobachtetes Entwicklungsfeld mit kurzer Begrueundung]

5 Quellen und Hilfsmittel

Die Quellenangaben werden vor Abgabe in einem einheitlichen Zitierstil finalisiert.

Waack, J.-M. (2026).

Bewertungshinweise ADA, Sommersemester 2026. Verwendung: Anforderungen und Bewertung des E-Portfolios.

OpenML, Datensatz ID 45566.

Santander Customer Transaction Prediction. Verwendung: reproduzierbare Datenquelle; Abruf des Datensatzes im Projekt am 06.08.2026 dokumentiert.

Kaggle.

Santander Customer Transaction Prediction. Verwendung: Wettbewerbskontext und Aufgabenbeschreibung. **[NOCH AUSZUFUELLEN: finales Zugriffsdatum]**

Software.

Python, Jupyter, pandas, NumPy, SciPy, scikit-learn, matplotlib und seaborn. **[NOCH AUSZUFUELLEN: verwendete Versionen aus der Projektumgebung ergaenzen]**

Generative KI / Agentenunterstuetzung.

Im Arbeitsprozess wurde Agentenunterstuetzung fuer EDA- und Dokumentationsarbeiten verwendet. Ergebnisse wurden als Arbeitsstaende uebernommen und werden fachlich sowie strukturell nachgeprueft. **[NOCH AUSZUFUELLEN: Tool/Version, konkrete Einsatzzeiträume und relevante Prompts vollstaendig dokumentieren]**

5.1 KI- und Tool-Transparenz

Fuer die finale Abgabe werden relevante KI-Einsaetze mit Datum, Tool/Version, Zweck, Prompt bzw. Kurzbeschreibung, erzeugtem Ergebnis und eigener Pruefung dokumentiert. Insbesondere muessen nachtraegliche Korrekturen kenntlich bleiben, wenn ein Agent eine methodische oder strukturelle Entscheidung zunaechst unzureichend umgesetzt hat.

A Offene Punkte vor der Abgabe

- Reale Zeitaufwände im Logbuch ergänzen, soweit nachvollziehbar; keine Zeiten schätzen, wenn keine belastbare Grundlage existiert.
- Gruppentreffen und Abweichungen vom Gruppenplan anhand tatsächlicher Ereignisse ergänzen.
- Einschätzung der Gruppenmitglieder aus eigener Beobachtung vervollständigen.
- Softwareversionen, Zitierstil, Zugriffsdatum und KI-/Prompt-Dokumentation finalisieren.
- Nach Abschluss der Modellierungsphase die Zusammenfassung um Modellvergleich, Cross-Validation, Hyperparameter und finale Schlussfolgerung erweitern.
- In Overleaf nur die Portfolio-Hauptdatei kompilieren; Logbuch und Abbildungen werden automatisch eingebunden. Abbildungen, Querverweise und Seitenumfang vor Abgabe visuell prüfen.