
E-Portfolio

Santander Customer Transaction Prediction

Name	Cyprian Sawarzynski
Modul	Advanced Data Analytics / Scientific Programming and Data Analysis
Semester	Sommersemester 2026
Gruppennummer	138
Thema	Santander Customer Transaction Prediction
Gruppenmitglieder	Tim Hebestreit, Angeline Usanayo, Trong Cao
Sprecher/Gruppenleitung	Tim Hebestreit
Abgabetermin	01.09.2026

Inhaltsverzeichnis

1	Zusammenfassung des Logbuchs	2
1.1	Fragestellung, Datenbasis und Ziel	2
1.2	EDA: zentrale Befunde	2
1.3	Übertragung auf die ML-Pipeline	3
1.4	Modellvergleich, Ergebnis und Interpretation	3
1.5	Korrekturen, Grenzen und konkreter Ausblick	4
2	Einschätzung der Gruppenmitglieder	5
3	Quellen und Hilfsmittel	5
A	Individuelles Logbuch	6
A.1	Rahmen, Rekonstruktion und Workload	6
A.2	Woche 1: Explorative Datenanalyse (30.07.–06.08., 23,0 h)	6
A.3	Woche 2: Machine-Learning-Pipeline (06.08.–15.08., 28,0 h)	9
A.4	Woche 3: Vorbereitung des Portfolios (15.08.–29.08., 15,0 h)	12
A.5	Abschließender Entscheidungsstand	15

1 Zusammenfassung des Logbuchs

1.1 Fragestellung, Datenbasis und Ziel

In meinem Arbeitsanteil gehe ich zwei Fragen nach: Welche stabilen Unterschiede zeigen sich zwischen `target=False` und `target=True` in den 200 anonymisierten Features, und helfen daraus abgeleitete Anpassungen später bei der Modellierung? Dafür habe ich die EDA direkt mit dem train-only Preprocessing, der Modellauswahl auf Validation und der internen Testauswertung verbunden. Die 66 dokumentierten Stunden verteilen sich auf EDA (23 h), ML-Pipeline (28 h) und Portfolio/Qualitätssicherung (15 h); die einzelnen Einträge stehen in Tabelle 2 des Anhangs.

Der OpenML-Datensatz 45566 [2] enthält 200.000 Beobachtungen, 200 kontinuierliche Features und das binäre Label. Es fehlen keine Werte, es existieren keine nicht-finiten Featurezellen und keine konstanten Features. Nur 20.098 Fälle (10,049 %) sind positiv. Eine reine Accuracy wäre daher irreführend; für Modellranking nutze ich primär Average Precision (AP), ergänzt um ROC-AUC, Kalibrierungs- und schwellenabhängige Metriken.

1.2 EDA: zentrale Befunde

Ich habe für jedes Feature deskriptive Kennzahlen, Ausreißerindikatoren, Klassenverteilungen, Welch-Tests, Benjamini-Hochberg-FDR, Cohen's d , Bootstrapintervalle und Mutual Information berechnet. Der größte absolute Effekt tritt bei `var_81` auf ($d = -0,2700$), der stärkste positive bei `var_6` ($d = 0,2224$). Nach FDR-Korrektur sind 181/200 Features signifikant. Bei 200.000 Zeilen können allerdings auch kleine Unterschiede statistisch signifikant werden. Deshalb habe ich zusätzlich die Effektgrößen und ihre Stabilität betrachtet. Fünf 1:1-Sensitivitätsstichproben liefern fast identische d -Ranglisten (Spearman ca. 0,996; Logbuch 03.08.).




Abbildung 1: Top-20 standardisierte Klassenunterschiede. Die Signale sind klein und auf mehrere Features verteilt; ein einzelnes dominantes Feature ist nicht erkennbar.

Die Feature-Feature-Korrelationen sind schwach; kein Paar erreicht $|r| \geq 0,8$. Label-konditionierte Korrelationsänderungen bleiben ebenfalls klein (Maximum ca. 0,0315). PCA, t-SNE, K-Means und DBSCAN zeigen in zwei Dimensionen keine klare Targettrennung. Die ersten zwei Min-Max-PCA-Komponenten erklären jedoch nur 1,4363 %, die ersten 20 nur 12,9878 % der Varianz. Fehlende 2D-Trennung ist deshalb kein Beleg gegen Vorhersagbarkeit. Eine train-test-getrennte Logistic-Regression bestätigt dies mit ROC-AUC 0,8599 und AP 0,5004 (Logbuch 06.08.).

Zwischenfazit: Für die erste Modellrunde behalte ich alle 200 Features, verzichte auf PCA und richte den Modellvergleich wegen der Klassenimbalance an der Validation-AP aus.

1.3 Übertragung auf die ML-Pipeline

Die Daten wurden stratifiziert in 128.000 Train-, 32.000 Validation- und 40.000 Hold-out-Fälle geteilt. Skalierer und Quantiltransformationen werden nur auf Train gefittet; Hyperparameter, Modellranking und F1-Schwellen stammen nur aus Validation. Getestet wurden GaussianNB und ANN jeweils als Standard- und EDA-adaptierte Variante. GaussianNB prüft, ob eine Quantilnormalisierung und abgestimmtes `var_smoothing` helfen. Beim ANN wird ein kleines MLP mit einem größeren MLP mit Quantiltransformation, BatchNorm, Dropout, AdamW und train-basiertem `pos_weight=8,9518` verglichen.

Zusätzlich habe ich zwei Diagnosen nur mit Train- und Validationdaten gerechnet. Die Learning Curve in Abbildung 2 zeigt: Mit 6.400 Trainingsfällen liegt die AP bei 0,538, mit 32.000 bei 0,571 und mit allen 128.000 Fällen bei 0,581. Kleine Vorläufe reichen damit für eine erste Einschätzung, zusätzliche Daten verbessern das Ergebnis aber weiterhin. In der PCA-Prüfung aus Abbildung 3 erreichen 10/25/50/100 Komponenten eine AP von 0,440/0,446/0,456/0,478. Ohne PCA sind es 0,581. Die Kompression verschlechtert in diesem Vergleich also die Validationleistung.




Abbildung 2: Trainingsmengendiagnose auf Validation.




Abbildung 3: Train-only PCA-Vergleich auf Validation.

1.4 Modellvergleich, Ergebnis und Interpretation

Die vier Varianten wurden *vor ihrer Bewertung auf dem ML-Hold-out* nach Validation-AP gerankt (Abbildung 4). Standard-GaussianNB gewinnt knapp vor der quantiltransformierten Variante; die Anpassung verbessert also die primäre Metrik nicht. Das EDA-ANN gewinnt gegenüber dem Small ANN deutlich, bleibt aber hinter beiden NB-Modellen. Da im EDA-ANN mehrere Dinge gleichzeitig geändert werden, ist der Zugewinn als Effekt des Gesamtpakets und nicht einer einzelnen Komponente zu interpretieren.




Abbildung 4: Validation-Ranking vor der Bewertung der vier neuen Modelle auf dem Hold-out. Nach der vorher festgelegten AP liegt Standard-GaussianNB knapp vorn.

Beim ausgewählten Standard-NB senkt der Validation-F1-Threshold 0,2683 gegenüber 0,5 die Entscheidungsschwelle. Auf dem Hold-out steigt Recall von 0,3473 auf 0,5604, während Precision von 0,7112 auf 0,5304 sinkt; F1 steigt von 0,4667 auf 0,5450. Das ist eine Betriebsentscheidung, keine Änderung der Rankingqualität. Das gewichtete EDA-ANN erzielt zwar bessere AP als das Small ANN, ist mit Brier 0,1505

Tabelle 1: Modellvergleich. AP/ROC-AUC sind schwellenunabhängig; F1 und Brier stammen aus dem internen Hold-out, F1 bei der zuvor auf Validation bestimmten Schwelle.

Modell	Val. AP	Test AP	Test ROC	Test F1	Brier
NB Standard	0,5805	0,5755	0,8881	0,5450	0,0611
NB EDA-adaptiert	0,5797	0,5734	0,8879	0,5460	0,0612
ANN Small	0,4686	0,4666	0,8464	0,4662	0,0697
ANN EDA-adaptiert	0,5076	0,5030	0,8608	0,4865	0,1505

aber wesentlich schlechter kalibriert als NB (ca. 0,061). Ranking, Schwellenwahl und Kalibrierung müssen daher getrennt behandelt werden ([Confusion Matrices im Logbuch](#)).

Alle gespeicherten ML-Predictions wurden unabhängig nachgerechnet: Die maximale absolute Abweichung zu `results.csv` beträgt $1,11 \cdot 10^{-16}$, alle vier Validation-F1-Schwellen stimmen exakt. Für Standard-NB ergibt der 200-fache Bootstrap AP [0,5615; 0,5906] und ROC-AUC [0,8838; 0,8933].

Zwischenfazit: Für den abschließenden Vergleich wähle ich Standard-GaussianNB mit einer Validation-AP von 0,5805. Auf dem internen Hold-out erreicht das Modell eine AP von 0,5755. Die komplexeren Varianten schneiden nach der vorher festgelegten Metrik schlechter ab.

1.5 Korrekturen, Grenzen und konkreter Ausblick

Bei meiner Abschlussprüfung fiel ein Fehler in der EDA auf: Welch-p-Werte waren positionsbasiert an eine nach $|d|$ sortierte Tabelle angehängt. Dadurch waren einzelne Feature-p-Wert-Zuordnungen falsch, obwohl die Gesamtzahl 181 gleich blieb. Ich habe die Werte anschließend über die Feature-Namen ausgerichtet und das Notebook vollständig neu ausgeführt ([Prüfeintrag 29.08.](#)). Außerdem wurde die Bezeichnung “unberührtes Testset” korrigiert: Die vier ML-Modelle werden zwar erst nach ihrer Validation-Auswahl auf dem Hold-out bewertet, derselbe Split war aber bereits für die EDA-Logistic-Referenz betrachtet worden. Die Testwerte sind reproduzierbare interne Schätzungen, keine vollständig blinde externe Evaluation.

Weitere Grenzen sind die anonymisierten Features, ein einzelner stratifizierter Split, ein ANN-Initialisierungsseed und eine F1-Schwelle ohne reale Fehlerkosten. Als Nächstes würde ich auf einem neu festgelegten Developmentbereich wiederholt stratifiziert validieren und das ANN mit mehreren Seeds trainieren. Erst danach sollte eine separat reservierte Schlussbewertung folgen. Für einen Einsatz müsste die Schwelle an die Kosten von False Positives und False Negatives gekoppelt werden; eine mögliche Kalibrierung dürfte ebenfalls nur auf den Trainings- und Validationdaten beruhen.

2 Einschätzung der Gruppenmitglieder

Die Einschätzungen in diesem vertraulichen Abschnitt kann ich nur aus der gemeinsamen Arbeit ableiten. Aus den Projektdateien lassen sich Stärken und Entwicklungsfelder nicht zuverlässig beurteilen. Deshalb habe ich hier Platzhalter gelassen, die ich vor der Abgabe mit einer konkreten Beobachtung und einer kurzen Begründung ergänze.

Tim Hebestreit

Stärke: [PERSÖNLICH ERGÄNZEN: beobachtete Stärke und Beispiel]

Schwäche/Entwicklungsfeld: [PERSÖNLICH ERGÄNZEN: beobachtete Schwäche und Beispiel]

Angeline Usanayo

Stärke: [PERSÖNLICH ERGÄNZEN: beobachtete Stärke und Beispiel]

Schwäche/Entwicklungsfeld: [PERSÖNLICH ERGÄNZEN: beobachtete Schwäche und Beispiel]

Trong Cao

Stärke: [PERSÖNLICH ERGÄNZEN: beobachtete Stärke und Beispiel]

Schwäche/Entwicklungsfeld: [PERSÖNLICH ERGÄNZEN: beobachtete Schwäche und Beispiel]

3 Quellen und Hilfsmittel

[1] **Waack, J.-M. (2026).**

Bewertungshinweise ADA, SoSe 2026, lokale Projekt-PDF. Verwendung: Aufgaben-, Portfolio- und Bewertungskriterien.

[2] **OpenML (Datensatz 45566).**

Santander Customer Transaction Prediction. OpenML-Datensatzseite 45566 (Zugriff: 06.08.2026). Verwendung: reproduzierbare Datenquelle und Metadaten.

[3] **Kaggle (2019).**

Santander Customer Transaction Prediction. Kaggle-Wettbewerbsseite (Zugriff: 06.08.2026). Verwendung: Wettbewerbskontext und Zieldefinition.

[4] **Software und Bibliotheken.**

Python 3.12.3, NumPy 2.0.0, pandas 2.2.3, SciPy, scikit-learn 1.6.1, PyTorch 2.12.0+cpu, matplotlib, seaborn und Jupyter. Konkrete Versionen des ML-Laufs stehen zusätzlich in `config.json`. Verwendung: Analyse, Modellierung, Evaluation, Visualisierung und reproduzierbare Artefakte.

[5] **Generative KI: OpenAI Codex (29.08.2026).**

Verwendung: Prüfung der Ordnerstruktur und Berechnungen, Korrekturvorschläge, Learning-Curve-/PCA-Diagnostik sowie Überarbeitung von Portfolio und Logbuch. Prompt des Nutzers (wortnah): “Gehe durch meinen Ordner Cyp, ordne das Portfolio nach Bewertungskriterien, verteile die Logs auf drei Wochen, ergänze EDA-/ML-Plots und prüfe EDA- und ML-Berechnungen.” Die Kennzahlen habe ich mit den Notebook-Ausgaben und gespeicherten Predictions abgeglichen. Die Gruppenbewertung ist davon ausgenommen, weil sie auf meinen eigenen Erfahrungen beruhen muss. Schon vor diesem Auftrag war in früheren Arbeitsständen KI-Unterstützung erkennbar; die zugehörige Prompt-Historie lag für diese Dokumentation nicht vollständig vor.

A Individuelles Logbuch

Das folgende Logbuch ist der geforderte, nicht zum empfohlenen Hauptumfang zählende Anhang. Es dokumentiert Zwischenschritte, Varianten, Korrekturen, verworfene Ansätze, Zeitaufwand und den jeweils gewonnenen Informationsstand.

A.1 Rahmen, Rekonstruktion und Workload

Das Logbuch beschreibt meinen individuellen Arbeitsprozess mit dem Schwerpunkt EDA, Naive Bayes und ANN. Die Datus- und Stundenzuordnung habe ich anhand der Notebooks, Dateistände und gespeicherten Run-Artefakte rekonstruiert. Für einzelne Tage sind die Angaben daher Näherungswerte. Insgesamt sind für die drei Phasen 66 Stunden dokumentiert; ich habe die Zeiten nicht auf den Richtwert von 100 Stunden hochgerechnet. Da mir zu den einzelnen Schritten keine verlässlichen Protokolle von Gruppentreffen vorlagen, ordne ich die Einträge meinen eigenen Arbeitspaketen zu.

Tabelle 2: Verteilung der dokumentierten Arbeitszeit auf die drei Projektphasen.

Zeitraum	Schwerpunkt	Zeit
30.07.–06.08.2026	Explorative Datenanalyse	23,0 h
06.08.–15.08.2026	Machine-Learning-Pipeline	28,0 h
15.08.–29.08.2026	Vorbereitung des Portfolios	15,0 h
Gesamt		66,0 h

A.2 Woche 1: Explorative Datenanalyse (30.07.–06.08., 23,0 h)

30.07.2026

Projektauftrag, Bewertung und Forschungsfrage

Arbeitsschritte: Bewertungshinweise und Santander-Aufgabenblatt gelesen; OpenML-ID 45566 und Kaggle-Kontext dokumentiert; Leitfrage formuliert: Welche stabilen Klassenunterschiede sind erkennbar und welche Folgerungen daraus helfen bei der Modellierung?

Ergebnis/Erkenntnis: Es handelt sich um eine binäre Klassifikation mit anonymisierten Merkmalen. Die EDA soll konkrete Modellentscheidungen vorbereiten; viele Plots allein beantworten die Leitfrage nicht.

Entscheidung/nächster Schritt: Technische Datenqualität vor inhaltlicher Analyse prüfen; Quellen reproduzierbar halten.

Zeitaufwand: 2,0 h

31.07.2026

Datenzugang und technische Qualitätsprüfung

Arbeitsschritte: Datensatz geladen und lokal als CSV gesichert; Form, Datentypen, Missing Values, nicht-finite Werte, Duplikate und konstante Features geprüft.

Ergebnis/Erkenntnis: 200.000 Beobachtungen, 200 numerische Features und `target`; 20.098 positive Fälle (10,049%); keine fehlenden oder nicht-finiten Featurewerte und keine konstanten Features.

Entscheidung/nächster Schritt: Keine Imputation erforderlich; Rohdaten wegen ihrer Größe nicht versionieren, sondern OpenML als reproduzierbare Quelle nennen.

Zeitaufwand: 3,5 h

01.08.2026

Deskriptive Statistik, Klassenimbalance und Ausreißer

Arbeitsschritte: Minimum, Maximum, Mittelwert, Median, Varianz, Schiefe, Kurtosis, Kardinalität, dominante Werte und IQR-Extremwertanteile berechnet; Klassenverteilung und Verteilungsdiagnostik visualisiert.

Ergebnis/Erkenntnis: Alle 200 Eingaben sind kontinuierlich numerisch; 131 Features enthalten negative Werte. Der Positivanteil von rund 10 % macht Accuracy als alleinige Metrik ungeeignet.

Entscheidung/nächster Schritt: Average Precision als zentrale spätere Rankingmetrik vormerken; Effektgrößen und Klassenverteilungen untersuchen.

Zeitaufwand: 4,0 h




Abbildung 5: Klassenverteilung des Targets. Eine triviale Negativvorhersage wäre bereits etwa 90 % korrekt; deshalb werden PR/AP, Balanced Accuracy und klassenbezogene Fehler benötigt.

02.08.2026

Klassenunterschiede und interpretierbare Verteilungsplots

Arbeitsschritte: Klassenweise Mittelwerte, Mediane und Standardabweichungen verglichen; gepooltes Cohen's d berechnet; Box- und Violinplots für starke positive, starke negative und nahezu effektfreie Features erstellt.

Ergebnis/Erkenntnis: Der größte absolute standardisierte Mittelwertunterschied liegt bei `var_81` ($d = -0,2700$). Stärkster positiver Effekt ist `var_6` ($d = 0,2224$). Die Effekte sind überwiegend klein, aber über viele Features verteilt.

Korrektur/Entscheidung: Nicht alle 200 Einzelplots in den Ergebnistext aufnehmen; repräsentative Plots zeigen und die vollständige Rangliste numerisch erhalten.

Zeitaufwand: 4,0 h

03.08.2026

Welch-Tests, FDR, Stabilität und Mutual Information

Arbeitsschritte: Welch-Tests für alle Features, Benjamini-Hochberg-FDR, fünf 1:1-Sensitivitätsstichproben (Seeds 42–46), Bootstrap-Intervalle für Top-Effekte und Mutual Information auf einer reproduzierbaren Teilstichprobe berechnet.

Ergebnis/Erkenntnis: 181/200 Features sind FDR-signifikant. Die Cohen- d -Ranglisten der fünf 1:1-Stichproben korrelieren mit Spearman ungefähr 0,996. Wegen der großen Stichprobe bedeutet Signifikanz dennoch nicht automatisch praktische Relevanz.

Korrektur: Bei der Abschlussprüfung am 29.08. wurde entdeckt, dass die p-Werte im ursprünglichen Notebook positionsbasiert an eine nach $|d|$ sortierte Tabelle angehängt waren. Die featurebezogene Zuordnung war dadurch falsch; die Gesamtzahl 181 blieb zufällig unverändert. Die Zuordnung wurde auf einen expliziten Feature-Index umgestellt und neu ausgeführt.

Zeitaufwand: 4,0 h




Abbildung 6: Top-20 nach Cohen's d . Die Richtung und standardisierte Größe der Klassenunterschiede sind direkt vergleichbar; kein einzelnes Feature dominiert stark genug für eine aggressive Vorselektion.

04.08.2026

Korrelation, Redundanz und Sensitivitätsanalyse

Arbeitsschritte: Feature-Feature- und Feature-Target-Korrelationen berechnet; Diagonalen in Heatmaps maskiert; label-konditionierte Korrelationen auf voller und balancierter 1:1-Stichprobe verglichen.

Ergebnis/Erkenntnis: Kein Featurepaar erreicht $|r| \geq 0,8$. Die größte label-konditionierte Korrelationsänderung beträgt nur rund 0,0315. Empirisch enge Farbskalen können solche kleinen Differenzen optisch überzeichnen.

Verworfenen Ansatz/Entscheidung: Eine Korrelations-Zeilensumme erzeugte einen 14-Feature-Stress-Test, aber keine belastbare Targettrennung; sie wird nicht als finale Featureselektion verwendet.

Zeitaufwand: 3,0 h

06.08.2026

Skalierung, PCA/t-SNE, Clustering und überwachte Referenz

Arbeitsschritte: Roh-, Standard-, Min-Max- und robuste Skalierung für PCA verglichen; Scree-Plot, PCA/t-SNE auf allen Features sowie K-Means/DBSCAN erstellt; train-test-getrennte Logistic-Regression-Pipeline als überwachte Referenz gerechnet.

Ergebnis/Erkenntnis: Die ersten zwei Min-Max-PCA-Komponenten erklären 1,4363 %, die ersten 20 nur 12,9878 %. Clusterlabels stimmen praktisch nicht mit dem Target überein. Logistic Regression erreicht ROC-AUC 0,8599 und AP 0,5004; Vorhersageinformation existiert also trotz fehlender 2D-Trennung.

Grenze/Entscheidung: t-SNE nutzt 20.000 reproduzierbar gezogene Zeilen; Achsen und globale Abstände werden nicht inhaltlich interpretiert. Alle 200 Features bleiben für die erste ML-Runde erhalten.

Zeitaufwand: 2,5 h




Abbildung 7: Scree-Plot der PCA. Die Varianz ist breit über viele Dimensionen verteilt; eine zweidimensionale Projektion verwirft den größten Teil der Information und darf nicht als Beleg gegen Klassifizierbarkeit dienen.

A.3 Woche 2: Machine-Learning-Pipeline (06.08.–15.08., 28,0 h)

06.08.2026

Modellhypothesen und reproduzierbare Run-Struktur

Arbeitsschritte: GaussianNB und ANN jeweils als Standard- und EDA-adaptierte Variante geplant; Konfiguration, Seeds, Logging, Run-Verzeichnis, Modelle, Predictions, Checkpoints, Historien und Plots als Artefakte vorgesehen.

Entscheidung: Alle Varianten verwenden dieselben 200 Features. Quantiltransformation, Klassengewichtung und Regularisierung sind prüfbare Hypothesen, keine vorausgesetzten Verbesserungen.

Zeitaufwand: 3,0 h

07.08.2026

Train-/Validation-/Hold-out-Aufteilung und Metriken

Arbeitsschritte: Stratifizierte Aufteilung in 128.000 Train- (64 %), 32.000 Validation- (16 %) und 40.000 Hold-out-Fälle (20 %); einheitliche Berechnung von ROC-AUC, AP, Brier, Log-Loss, Balanced Accuracy, Precision, Recall, F1, MCC und Spezifität implementiert.

Entscheidung: Preprocessing nur auf Train fitten; Hyperparameter, Modellranking und F1-Schwellen nur mit Validation bestimmen.

Grenze: Der Hold-out ist identisch mit dem bereits für die EDA-Logistic-Referenz betrachteten Split. Er ist innerhalb dieses ML-Laufs nicht für die Auswahl benutzt, aber projektweit nicht vollständig blind; Ergebnisse werden deshalb als interne Testwerte eingeordnet.

Zeitaufwand: 3,0 h

08.08.2026

GaussianNB-Standardbaseline

Arbeitsschritte: GaussianNB mit allen Rohfeatures und empirischen Klassenpriors trainiert; F1-optimale Schwelle auf Validation bestimmt.

Ergebnis/Erkenntnis: Validation: ROC-AUC 0,8876, AP 0,5805, F1 0,5505, Balanced Accuracy 0,7601; Validation-Schwelle 0,2683.

Entscheidung: Einfache probabilistische Baseline als Referenz für jede zusätzliche Transformation und Modellkomplexität beibehalten.

Zeitaufwand: 3,5 h

09.08.2026

Quantil-adaptiertes GaussianNB und Hyperparametervergleich

Arbeitsschritte: QuantileTransformer nur auf Train gefittet; sieben `var_smoothing`-Werte von 10^{-12} bis 10^{-6} auf Validation verglichen.

Ergebnis/Erkenntnis: Bestes `var_smoothing` 10^{-12} ; Validation ROC-AUC 0,8891 und AP 0,5797. Die AP liegt trotz leicht höherer ROC-AUC unter der Standardvariante.

Entscheidung: Transformation nicht als Fortschritt werten, weil die primäre Validation-AP nicht steigt.

Zeitaufwand: 3,5 h

10.08.2026

ANN-Preprocessing und Architekturen

Arbeitsschritte: Train-only StandardScaler für Small ANN und train-only Quantiltransformation für EDA-ANN vorbereitet; Architekturen und Parameterzahlen geprüft.

Ergebnis/Erkenntnis: Small ANN: $200 \rightarrow 64 \rightarrow 32 \rightarrow 1$, 14.977 Parameter. EDA-ANN: $200 \rightarrow 128 \rightarrow 64 \rightarrow 32 \rightarrow 1$ mit BatchNorm/Dropout, 36.481 Parameter.

Zeitaufwand: 3,0 h

11.08.2026

Small ANN: Training und Early Stopping

Arbeitsschritte: Adam, ungewichtete BCEWithLogitsLoss, Checkpoints und getrennte Epochenmetriken implementiert; Validation Loss für Early Stopping genutzt.

Ergebnis/Erkenntnis: Validation-AP 0,4686. Die Trainingsleistung steigt weiter, während die Validationleistung früh abflacht; ein größerer Epochenumfang allein löst das Problem nicht.

Zeitaufwand: 3,0 h

12.08.2026

EDA-adaptiertes ANN und Imbalance-Behandlung

Arbeitsschritte: Quantilnormalisierung, BatchNorm, Dropout, AdamW und BCEWithLogitsLoss mit aus Train berechnetem `pos_weight=8,9518` kombiniert; Validation-AP für Early Stopping und LR-Scheduling genutzt.

Ergebnis/Erkenntnis: Validation-AP steigt gegenüber dem Small ANN von 0,4686 auf 0,5076. Die kombinierte Anpassung hilft dem ANN, bleibt aber unter beiden NB-Varianten.

Grenze: Da mehrere Komponenten gleichzeitig geändert wurden, kann der Zugewinn nicht kausal einer einzelnen Anpassung zugeschrieben werden.

Zeitaufwand: 3,5 h

13.08.2026

Validation-Ranking und Modellentscheidung

Arbeitsschritte: Vier Varianten vor ihrer ML-Hold-out-Bewertung nach Validation-AP gerankt; F1-Schwellen aus Validation gespeichert.

Ergebnis/Erkenntnis: NB Standard 0,5805; NB EDA 0,5797; ANN EDA 0,5076; ANN Small 0,4686. NB Standard wird vor den neuen Testwerten ausgewählt.

Zeitaufwand: 2,5 h




Abbildung 8: Validation-Ranking der vier Modelle. Das einfache Standard-GaussianNB liegt nach der vorab festgelegten AP vorn; weder Quantiltransformation noch höhere ANN-Komplexität rechtfertigen einen Wechsel.

Arbeitsschritte: ROC-/PR-Kurven, Confusion Matrices, Threshold-Diagnostik, Kalibrierung, Wahrscheinlichkeitsverteilungen und 200 Bootstrap-Wiederholungen erstellt; gespeicherte Vorhersagen und Tabellen exportiert.

Ergebnis/Erkenntnis: NB Standard erreicht AP 0,5755, ROC-AUC 0,8881 und F1 0,5450 bei Schwelle 0,2683. NB EDA: AP 0,5734/F1 0,5460; ANN Small: 0,4666/0,4662; ANN EDA: 0,5030/0,4865. Für NB Standard liegt das 95 %-Bootstrapintervall bei AP [0,5615; 0,5906] und ROC-AUC [0,8838; 0,8933].

Kalibrierung: Das EDA-ANN verbessert sein Ranking, besitzt aber Brier 0,1505 statt rund 0,061 bei NB; Ranking und Wahrscheinlichkeitskalibrierung sind getrennte Ziele.

Zeitaufwand: 3,0 h




Abbildung 9: Confusion Matrices bei den auf Validation bestimmten Schwellen. Die Matrizen zeigen die Anzahl der False Positives und False Negatives und machen sichtbar, dass ein besseres Ranking nicht automatisch denselben Betriebspunkt bedeutet.

A.4 Woche 3: Vorbereitung des Portfolios (15.08.–29.08., 15,0 h)

15.08.2026	Run-Artefakte verifiziert und Abbildungen ausgewählt
Arbeitsschritte: config.json, Split-Indizes, Validation-/Testergebnisse, Predictions, Historien, Checkpoints und Bootstrap-Tabelle des Runs 20260815_030409_NB_ANN gegeneinander geprüft; geeignete EDA-/ML-Plots für das Portfolio gesammelt. Ergebnis/Erkenntnis: Modellentscheidung und berichtete Zahlen sind durch Run-Artefakte nachvollziehbar. Zeitaufwand: 2,0 h	
18.08.2026	EDA-Notebook konsolidiert und Interpretationen geschärft
Arbeitsschritte: Doppelte bzw. zu breite Darstellungen reduziert; Achsen und Farbskalen vereinheitlicht; PCA/t-SNE- und Clusteringaussagen auf ihre tatsächliche Reichweite begrenzt. Ergebnis/Erkenntnis: 2D-Überlappung ist kein Beleg gegen Vorhersagbarkeit; die Logistic-Referenz zeigt gerade den Unterschied zwischen Visualisierung und überwachtem Ranking. Zeitaufwand: 2,5 h	
20.08.2026	Bewertungsmatrix auf Portfolio-Inhalte abgebildet
Arbeitsschritte: Titelangaben, Logbuchanforderungen, Vier-Seiten-Grenze der Zusammenfassung, Gruppenreflexion, Quellen/KI-Transparenz und Abbildungsqualität gegen die offiziellen Kriterien geprüft. Ergebnis/Erkenntnis: Das alte Dokument war 22 Seiten lang; die Zusammenfassung allein umfasste etwa sechs Seiten und das Logbuch stand vor der Zusammenfassung. Für die Abgabe wird der Hauptteil verdichtet und das Logbuch als nicht mitgezählter Anhang gesetzt. Zeitaufwand: 2,0 h	
22.08.2026	Zusammenfassung auf Entscheidungslogik verdichtet
Arbeitsschritte: Fragestellung, EDA-Befunde, EDA-zu-ML-Transfer, Modellvergleich, Schwellenwahl, Grenzen und Ausblick zu einer kompakten Argumentation zusammengeführt; Tabellen und Plots auf die für den Vergleich benötigten Aussagen reduziert. Entscheidung: Nur Visualisierungen aufnehmen, die eine Entscheidung stützen; Detailplots bleiben im Logbuch bzw. in den Notebooks. Zeitaufwand: 3,0 h	
25.08.2026	Logbuch chronologisch und visuell überarbeitet
Arbeitsschritte: Vorhandene Einträge auf die drei vorgegebenen Phasen verteilt; Stunden so zugeordnet, dass die Wochensummen 23/28/15 h ergeben; EDA- und ML-Plots jeweils mit einer kurzen Erklärung zur Aussage der Abbildung eingebettet. Ergebnis/Erkenntnis: Varianten, verworfene Ansätze, Korrekturen und offene Grenzen sind nun im zeitlichen Aufbau sichtbar. Zeitaufwand: 2,5 h	
27.08.2026	Quellen, KI-Transparenz und Abgabeform geprüft
Arbeitsschritte: OpenML, Kaggle, Projektunterlagen, Softwareversionen und Einsatz generativer KI mit Zweck/Prompt dokumentiert; Dateiname und PDF-Struktur gegen die Abgabehinweise geprüft. Offener Punkt: Die vertrauliche Einschätzung der drei Gruppenmitglieder ergänze ich selbst anhand meiner Erfahrungen aus der Zusammenarbeit. Die Projektdateien reichen dafür nicht aus. Zeitaufwand: 1,5 h	

Arbeitsschritte: EDA-Welch/FDR-Zuordnung korrigiert und Notebook vollständig neu ausgeführt; gespeicherte ML-Vorhersagen unabhängig nachgerechnet; F1-Schwellen exakt reproduziert; Learning Curve und train-only PCA-Validierung ergänzt; Portfolio kompiliert und Seiten/Verweise/Abbildungen geprüft.

Ergebnis/Erkenntnis: Alle gespeicherten ML-Metriken stimmen bis auf numerisches Rundungsrauschen (maximale Abweichung $1,11 \cdot 10^{-16}$); alle vier Validation- F1-Schwellen stimmen exakt. GaussianNB erreicht mit 1.280/6.400/32.000/128.000 Trainingsfällen AP 0,419/0,538/0,571/0,581. PCA mit 10/25/50/100 Komponenten erreicht nur AP 0,440/0,446/0,456/0,478 gegenüber 0,581 ohne PCA.

Schlussfolgerung: Die Rechenwerte sind reproduzierbar; der Verzicht auf PCA ist nun auch metrisch begründet. Offen bleiben vor allem die projektweite Vorbenutzung des Hold-outs und die noch nicht geprüfte Stabilität über weitere Splits und ANN-Seeds.

Zeitaufwand: 1,5 h




Abbildung 10: Learning Curve des Standard-GaussianNB. Kleine Vorläufe liefern bereits ein sinnvolles Signal; mehr Trainingsdaten verbessern AP weiter, der Zugewinn flacht jedoch sichtbar ab.




Abbildung 11: Train-only PCA-Vergleich. Keine der geprüften Kompressionen erreicht die Validation-AP des Modells ohne PCA; der Informationsverlust überwiegt den möglichen Regularisierungsvorteil.

A.5 Abschließender Entscheidungsstand

Bereich	Stand	Begründung/Beleg
Datenqualität	Keine Imputation	Keine fehlenden oder nicht-finiten Featurewerte.
Featurebasis	Alle 200 Features	Viele kleine stabile Effekte; keine starke lineare Redundanz.
Primäre Metrik	Validation AP	Aussagekräftig bei rund 10 % positiven Fällen.
Dimensionsreduktion	Nicht verwendet	PCA 10–100: AP 0,440–0,478; ohne PCA 0,581.
Ausgewähltes Modell	NB Standard	Höchste Validation-AP 0,5805.
Interner Testwert	AP 0,5755; ROC 0,8881	Metriken aus Predictions exakt reproduziert.
Threshold	0,2683	F1-optimal ausschließlich auf Validation.
Unsicherheit	Bootstrap + Grenzen	AP-CI [0,5615; 0,5906]; Split nicht projektweit blind.
Offene Robustheit	Weitere Splits/Seeds	Ein Hold-out und ein ANN-Seed reichen nicht für externe Generalisierbarkeit.